




图 2-11 4D 系统训练结果




图 2-12 4D 系统训练结果

不变集，蓝色部分为采样点集 X_{safe} 中满足 CBF 上确界条件的充分条件的点，黄色部分为使用本章节方法训练得到的分片仿射网络中 $h(\mathbf{x}) \geq 0$ 点的部分。同样此时的分片仿射网络 $h(\mathbf{x})$ 满足所有 CBF 条件，可证明黄色部分是一个控制不变集。其小于理论最大控制不变集的原因同二维实验后提出的三点。

四维系统去冗余后用于优化问题求解的平均点数（每次训练求解的优化问题平均个数）为 308.01，每次训练的平均时间约为 9.8731s，训练 400 次附近完全收敛，因此基于 CBF 训练获取 CIS 的时间约为 3949s。MPT 工具箱计算 CIS 的时间约为 569.85s。传统方法和训练方法时间比为 1:6.93，与二维相比时间比例缩小了许多。

2.4.3 九维系统实验

在九维三重积分器系统^[81]的实验中，系统的动态方程为 (2-60):

$$\mathbf{x}_{k+1} = \begin{bmatrix} 1 & T_s & T_s^2/2 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & T_s & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & T_s & T_s^2/2 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & T_s & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & T_s & T_s^2/2 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & T_s \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix} \mathbf{x}_k + \begin{bmatrix} T_s^3/6 & 0 & 0 \\ T_s^2/2 & 0 & 0 \\ T_s & 0 & 0 \\ 0 & T_s^3/6 & 0 \\ 0 & T_s^2/2 & 0 \\ 0 & T_s & 0 \\ 0 & 0 & T_s^3/6 \\ 0 & 0 & T_s^2/2 \\ 0 & 0 & T_s \end{bmatrix} \mathbf{u}_k \quad (2-60)$$

MPC 配置:

- 预测时域: $N_p = 20$, 表示控制器在每次优化时考虑的未来时域长度, 安全轨迹采样距离 $n = 1$ 。
- 采样周期: $T_s = 0.18$ 秒, 这表示每次采样系统状态的时间间隔。
- 状态约束: $\mathbf{x} \in [-2, 2]^3 \times [-1, 1]^3 \times [-2.83, 2.83]^3$, 这些约束确保了系统的安全操作。
- 控制约束: $\mathbf{u} \in [-59.3, 59.3]^3$, 限制了控制输入的范围, 确保控制输入不会超出物理设备的限制。
- 代价矩阵: $\mathbf{Q} = 2\mathbf{I}_9$, $\mathbf{R} = \mathbf{I}_3$, 该代价函数设计确保了状态和控制输入之间的平衡。
- 样本分布: 共 30,000 个点, 其中 10,000 个安全点和 20,000 个不安全点。为方便展示, 这里给出九维采样安全点分别在 1、2 维, ..., 1、9 维, 2、3 维, ..., 2、9 维, ..., 8、9 维共 36 个平面的投影图, 图见附录A-1~A-6。

训练过程:

- 热启动: 使用球初始化方法处理安全数据集。取凸包顶点数为 200, 确定每个凸包边的表达式系数 ω_m, b_m 。设固定点坐标 $\mathbf{C} = [0, 0, 0.1]$, 计算每个网络分片 h_m 的系数 $\hat{\omega}_m, \hat{b}_m$ 。
- 网络结构: 采用 $M = 200$ 个分片的分片仿射网络架构, 其中第 m 个分片 h_m 的参数设为 $\hat{\omega}_m$ 和 $\hat{b}_m$ 。
- 学习率: 选择初始学习率为 2×10^{-3} , 在训练过程使用 Adam 算法动态调整学习率, 以确保训练过程稳定收敛。
- 训练超参数设置: 仍类似 (2-58) 命名损失函数的每一项, 设改进 Loss 的微小量 $\varepsilon_1 = \varepsilon_2 = \varepsilon_3 = 0.075$ 。Loss 权重比设为 $c_1 : c_2 : c_3 = 100 : 2000 : 1$, 训练次

数为 1000 次，每次训练使用全部数据集。训练结果如附录图A-7~A-13。

由训练过程图A-7可见：在训练过程中三个 CBF 条件所对应的 Loss 都实现了收敛，同时对应的约束条件满足点数也收敛到较高的水平。可以一定程度上说明训练效果的有效性。由训练结果图A-8~A-13可见：对于每一个子图，以黑色框线为边界的多面体为 MATLAB MPT 工具箱计算得到的系统最大控制不变集，蓝色部分为采样点集 X_{safe} 中满足 CBF 上 s 确界条件的充分条件的点，黄色部分为使用本章节方法训练得到的分片仿射网络中 $h(\mathbf{x}) \geq 0$ 点的部分。同样此时的分片仿射网络 $h(\mathbf{x})$ 满足所有 CBF 条件，可证明黄色部分是一个控制不变集。其小于理论最大控制不变集的原因仍然同二维实验后提出的三点。

九维系统去冗余后用于优化问题求解的平均点数（每次训练求解的优化问题平均个数）为 302.96，每次训练的平均时间约为 19.5767s，训练 400 次附近完全收敛，因此基于 CBF 训练获取 CIS 的时间约为 7831s。而 MPT 工具箱短时间（24 小时）内无法计算出该 9 维系统的控制不变集。因此在九维条件下，使用 30000 个数据点进行训练根据 CBF 理论获取 CIS 比使用迭代法直接计算要快得多。

2.5 本章小结

本章首先在小节 2.1 与小节 2.2.1 介绍了 CBF 和分片仿射网络的先验知识。之后基于上述两点理论设计并提出了一种基于学习的通过学习控制障碍网络构造已知系统安全集（控制不变集）的方法，通过构造分片仿射神经网络（PWANN）以及基于 CBF 条件设计的损失函数，训练出一个满足 CBF 条件的分片仿射网络。该方法结合了模型预测控制的采样策略和多项损失函数的训练技术，同时利用了分片仿射网络的局部线性性质简化了基于 CBF 条件构造的 Loss 的计算过程，实现了高效且准确的学习框架，并经过多个维度系统的实验验证。实验结果表明该方法在保证 CBF 条件满足与否被准确评估的同时，给出了较为准确的安全集合，比起传统的基于迭代计算控制不变集的方法，一方面（尤其在高维系统）显著提升了获取结果集合的速度，另一方面对于迭代法无法计算的高维系统，本方法仍具有一定的效果且计算时间数量级并未显著增加。同时由于使用了分片仿射网络结构，最后得到的 CIS 是多面体形式，解释性更强，更方便在 MPC 等控制器上作为约束使用。

第3章 基于强化学习的机会约束优化问题求解

3.1 引言

第二章构建了一个分片仿射控制障碍函数网络，并在确定性场景下验证了其对于系统安全性的刻画能力，该部分工作侧重于确定系统优化问题中系统安全约束的建模与构造。然而，在现实应用中，真实系统通常会受到随机扰动与模型不确定性等因素的影响，这些不确定性使得基于理想确定性系统得到的结论难以直接适用。比如在自动驾驶、机器人路径规划等实际工程中，系统面临的不确定性和外部扰动复杂多变，因此研究机会约束优化问题不仅具有理论价值，也有重要的工程意义。为此，本文第三章与第四章将研究对象扩展至受扰动系统，重点关注在给定约束描述条件下的控制策略与优化问题。首先介绍受扰动系统下的优化问题形式——机会约束优化问题，随后分别从不同的优化框架出发，分析机会约束优化问题的求解方法。

本章从强化学习的角度研究随机系统下的控制策略优化问题，重点在于机会约束条件下的策略学习与性能优化，旨在探讨在给定约束描述条件下的控制问题求解方法。通过构建合理的控制策略和约束处理方法，可以在保证系统安全的前提下，提高控制性能和执行效率。

3.2 机会约束优化问题

在现实工程中，由于受到环境不确定性、测量误差、建模误差等因素的影响，很多优化问题都不可避免地包含不确定性。传统的确定性优化方法难以准确建模和解决这些不确定的影响。因此，在优化问题中考虑不确定性的存在，成为优化算法应用到现实中的一个重要研究方向。受扰动系统下的具有期望形式代价函数和概率不等式形式约束的优化问题，称为机会约束优化问题（Chance-Constrained Optimization Problem, CCOP）。这种问题的核心挑战在于如何在保证约束概率满足的前提下，尽可能优化系统性能指标，这使得传统的确定性优化方法难以直接适用。机会约束优化问题^[82]便是其中一种将不确定性建模到优化问题中并进行求解的优化方法。

3.2.1 机会约束优化问题的基本形式

CCOP 定义的基本思想是：由于受到不确定性影响，问题中具有了一定的随机性。其可能会影响代价函数或者约束函数的具体值，使代价函数和约束的值也具有一定的随机性。机会约束优化问题在优化问题中引入了具有一定先验信息的随机变量来建模这种随机性。对于涉及随机变量的不确定代价函数，我们转而在期望的形式代替原本的多项式形式。对于约束条件，允许其在小概率范围内被违反，即不是对所有随机情况都严格满足约束，而是以一定“置信水平”满足约束。这种方法可以在实际系统中引入合理的风险管理策略，使优化问题的可行解空间更为宽松，同时也更接近现实应用场景。一个典型的 CCOP 框架可写为以下形式：

$$\begin{aligned} \min_x \quad & \mathbb{E}[f(\mathbf{x}, \boldsymbol{\xi})] \\ \text{s.t.} \quad & \Pr(g(\mathbf{x}, \boldsymbol{\xi}) \leq 0) \geq 1 - \varepsilon \end{aligned} \quad (3-1)$$

式中 $\mathbf{x} \in X \subset \mathbb{R}^n$ ——系统的状态向量， X 为状态约束集合；

$\boldsymbol{\xi} \in \mathbb{R}^m$ ——具有先验信息（如分布函数、上下界、一阶矩与二阶矩等）的随机变量，用于刻画系统中的不确定性；

$f(\mathbf{x}, \boldsymbol{\xi})$ ——受不确定性影响的代价函数；

$g(\mathbf{x}, \boldsymbol{\xi})$ ——受不确定性影响的约束函数；

$\Pr\{\cdot\}$ ——概率算子；

$\varepsilon \in (0, 1)$ ——约束违反概率的上界，又称机会约束的置信水平。

3.2.2 机会约束优化问题的常见解法

从数学角度看，机会约束不同于一般确定性约束主要在于其提供了对不确定性的一种概率松弛，使优化问题更具有实际意义。在实际应用中，这种松弛意味着系统可以容忍一定程度的“风险”或者“失败”，而不追求绝对的安稳。如自动驾驶中的车道保持问题，用机会约束即可保证“车的位置以不小于设定值的概率保持在设定的车道范围内，而可以有一定概率偏离设定范围”。这比确定约束下“车的位置每时每刻都要保持在车道的设定范围内”更松弛，也更符合实际的车道保持场景，同时更容易有可行解。

虽然机会约束优化问题在问题建模方面具有一定的灵活性与现实意义，但求解这样的问题却具有一定的难度。首先，由于涉及概率计算，(3-1) 中的约束部分通常不能写成显式函数，难以使用传统优化算法求解。其次，即使 (3-1) 中

的 $g(\mathbf{x}, \xi)$ 是凸函数, 整体机会约束函数可能仍是非凸的, 这会导致求解困难。很多对机会约束优化问题的求解方法依赖于随机采样, 如情景优化^[83], 样本平均近似^[84]等, 但由于涉及采样, 这会导致计算成本变高。其他常见求解方法还有闭式逼近法^[85]、鲁棒优化近似法等^[86]。尽管如此, 这些方法仍然为实际问题提供了可行的近似解, 也为后续强化学习方法的比较提供了理论参考。

总之, 机会约束优化是一种重要的不确定优化建模工具, 其兼顾了模型的现实性与系统控制的鲁棒性。然而其涉及的机会约束带来了额外的计算复杂性与优化求解问题。对不同涉及优化问题求解的控制器提出了挑战。本文第三章和第四章将分别在强化学习和模型预测控制这两种广泛使用的控制器的框架下, 对机会约束优化问题的求解进行理论方面的研究和实验验证。

3.3 强化学习的基本原理

强化学习 (Reinforcement Learning, RL) 本质上是在求解一个贝尔曼最优方程 (Bellman Optimal Equation, BOE), 因此如果想要让 RL 算法求解特定的优化问题, 就需要先写出对应优化问题的 BOE。

首先, 最简单的优化问题到 BOE 的转化过程是从无约束优化问题到 BOE 的转化。在已知单步代价函数和环境模型时, 可以直接通过马尔可夫决策过程 (Markov Decision Process, MDP) 的性质和贝尔曼最优定理写出 BOE。

进一步, 当考虑带有约束的优化问题时。由于约束的限制, 优化问题不能直接转化成 BOE。而是需要通过将硬约束处理成软约束等方法, 先将有约束优化问题转化为无约束优化问题, 再写出转化后无约束优化问题的 BOE, 并将其作为原有约束优化问题的 BOE。

更进一步, 机会约束优化问题是带有期望形式代价和概率不等式形式约束的优化问题, 在将其转化为无约束优化问题的过程中, 转化结果不仅需要满足可以写成 BOE 的形式, 还需要保证对应的 BOE 的解可以保证原机会约束的满足, 此外还要考虑如何有效地将概率不等式转化为软约束形式项加入到代价函数中。因此, 如何将有机会约束的优化问题转化为合适的 BOE, 使其可以通过 RL 方法求解, 且求解结果可以满足原机会约束的要求是本章在 RL 角度研究机会约束求解的重要内容。

3.3.1 从动态规划到强化学习

首先我们从动态规划的角度介绍从一般形式优化问题转化成强化学习问题的过程。动态规划 (Dynamic Programming, DP) 是一种常用于求解优化问题

的方法，其尤其适用于具有“最优子结构”和“重叠子问题”性质的问题。

最优子结构是指：一个问题的最优解可以通过子问题的最优解组合而成，即一个问题的解可以通过解决其子问题来获得，比如最短路径问题中，如果某条路径是最短的，那么路径的每一部分也是最短的。

重叠子问题是指：原问题可以分解成多个子问题，且这些子问题是重复出现的。可以通过记录已经计算过的子问题的结果以避免重复计算。例如斐波那契数列的计算过程。

DP 将复杂问题分解成小的子问题同时记录子问题的解，并通过重复使用子问题的解避免了重复计算，优化了算法的时间效率。这种方法的优势在于，它能够充分利用问题结构，使强化学习在高维状态空间中仍能有效逼近最优策略。

3.3.1.1 贝尔曼方程

贝尔曼方程（Bellman Equation, BE）也被称作动态规划方程。是动态规划能够达到最优的必要条件。几乎所有可以用最优控制理论解决的问题都可以通过构建合适的贝尔曼方程得到解决。下面简单介绍一般优化问题下贝尔曼方程的推导。

设系统在 t 时刻的状态为 $\mathbf{x}_t$ ，初始时刻为 0 时刻，因此设初始状态为 $\mathbf{x}_0$ 。设 t 时刻的控制变量为 $\mathbf{a}_t$ ，且每一时刻的输入可行的集合 Γ 和当前时刻状态有关，即 $\mathbf{a}_t \in \Gamma(\mathbf{x}_t)$ 。当采取控制变量 $\mathbf{a}_t$ 时，状态将由 $\mathbf{x}_t$ 转到 $\mathbf{T}(\mathbf{x}_t, \mathbf{a}_t)$ ， $\mathbf{T}(\mathbf{x}, \mathbf{a})$ 被称为状态转移函数。同时记在状态 $\mathbf{x}_t$ 采取控制变量 $\mathbf{a}_t$ 后获取的收益记为 $F(\mathbf{x}_t, \mathbf{a}_t)$ 。最后使用折扣因子 $\gamma, 0 \leq \gamma \leq 1$ 平衡当前时刻与较远时刻收益间的影响。基于这些假设，我们可以定义一个无限时域的优化问题：

$$\begin{aligned} V(\mathbf{x}_0) &= \max_{\{\mathbf{a}_t\}_{t=0}^{\infty}} \sum_{t=0}^{\infty} \gamma^t F(\mathbf{x}_t, \mathbf{a}_t) \\ \text{s.t. } &\mathbf{a}_t \in \Gamma(\mathbf{x}_t) \\ &\mathbf{x}_{t+1} = \mathbf{T}(\mathbf{x}_t, \mathbf{a}_t), \quad \forall t = 0, 1, 2, \dots \end{aligned} \quad (3-2)$$

我们使用 $V(\mathbf{x}_0)$ 来表示上述问题的目标函数最优值。这个函数称为价值函数或者值函数，显然价值函数是初始值 $\mathbf{x}_0$ 的函数。

3.3.1.2 贝尔曼最优定理

前面提到使用动态规划方法可以将原优化问题分解为更小的子问题来求解，贝尔曼最优定理描述了这部分工作的具体流程。最优化原理指出：对于最优策略，无论初始状态或初始决策如何，后续的决策一定是基于初始决策所导

致的状态所形成的最优化策略。基于这个原理，我们可以将 (3-2) 中的无线时域优化问题转换为以下的等价形式：

$$\max_{\mathbf{a}_0} \left\{ F(\mathbf{x}_0, \mathbf{a}_0) + \gamma \left[\max_{\{\mathbf{a}_t\}_{t=1}^{\infty}} \sum_{t=1}^{\infty} \gamma^{t-1} F(\mathbf{x}_t, \mathbf{a}_t) \mid \mathbf{a}_t \in \Gamma(\mathbf{x}_t), \mathbf{x}_{t+1} = \mathbf{T}(\mathbf{x}_t, \mathbf{a}_t), \forall t \geq 1 \right] \right\} \quad (3-3)$$

式 (3-3) 表明，从初始 0 时刻开始求解最优控制序列 $\mathbf{A}_0 = \{\mathbf{a}_0, \mathbf{a}_1, \dots\}$ ，等价于先从 1 时刻开始求解最优控制序列 $\mathbf{A}_1 = \{\mathbf{a}_1, \dots\}$ 后，再求 0 时刻的最优控制量 $\mathbf{a}_0$ 后组成的控制序列 $\{\mathbf{a}_0, \mathbf{A}_1\}$ 。式 (3-2) 已经用函数 $V(\mathbf{x})$ 定义了从状态 $\mathbf{x}$ 出发的最优代价函数。因此式 (3-3) 还可以化简成式 (3-4) 的形式：

$$V(\mathbf{x}_0) = \max_{\mathbf{a}_0} \{F(\mathbf{x}_0, \mathbf{a}_0) + \gamma V(\mathbf{x}_1)\} \quad (3-4)$$

根据 $\mathbf{x}_1$ 与 $\mathbf{x}_0$ 的函数关系，最终优化问题的表达形式为：

$$V(\mathbf{x}_0) = \max_{\mathbf{a} \in \Gamma(\mathbf{x}_0)} \{F(\mathbf{x}_0, \mathbf{a}) + \gamma V(\mathbf{T}(\mathbf{x}_0, \mathbf{a}))\} \quad (3-5)$$

式 (3-5) 就是 BOE。BOE 是一个泛函方程，求解的是未知函数 $V(\mathbf{x})$ ，同时可以解出最优的控制量 $\mathbf{a}(\mathbf{x})$ 。

基于最优性定理，原优化问题被转化成了一个 BOE。只需要解出这个 BOE 的解，就可以得到原优化问题的最优解。

3.3.1.3 强化学习与贝尔曼最优方程

强化学习是求解贝尔曼方程的手段。当实现将优化问题转化称为 BOE 之后，就可以通过各种形式的强化学习框架对 BOE 进行求解，继而实现原优化问题的求解。而从式 (3-5) 可以看出，构建 BOE 需要知道状态转移方程 $\mathbf{T}(\mathbf{x}, \mathbf{a})$ ，价值函数 $F(\mathbf{x}, \mathbf{a})$ ，控制可行域 $\Gamma(\mathbf{x})$ 以及折扣系数 γ 。也就是说，知道上述四种方程和系数，就可以构建一个对应于原优化问题的 BOE。

本节从动态规划的角度介绍了强化学习的基本原理。在实现从优化问题到 BOE 的转化过程后，可以使用各种强化学习的框架对 BOE 进行求解。下节将介绍具体的强化学习求解框架。

3.3.2 Actor-Critic 框架

强化学习是一种基于数据迭代求解优化问题的方法。其主要分为值迭代和策略迭代两种。

值迭代是一种基于 BOE 的迭代求解方法，其通过不断更新状态的值函数 $V(\mathbf{s})$ (强化学习中状态常用 $\mathbf{s}$ 表示) 来逼近最优值函数 $V^*(\mathbf{s})$ ，从而找到最优策略 $\pi_*(\mathbf{s})$ 。值函数的每一步更新遵循 BOE：

$$V(s) = \max_a \left[F(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right] \quad (3-6)$$

式中 $V(s)$ ——状态 s 对应的值函数，表示从该状态出发并按照最优策略行动时所能获得的最大期望回报；

$F(s, a)$ ——在状态 s 下采取动作 a 后获得的即时奖励；

$P(s' | s, a)$ ——从状态 s 采取动作 a 转移到状态 s' 的概率；

γ ——折扣因子，用于权衡未来回报的重要性。

具体的更新过程为：首先对每个状态 s 给出初始的值函数 $V_0(s)$ ，之后按照 (3-6) 选择此值函数下每个状态的最优动作得到新的值函数 $V_1(s)$ ，重复这个过程直到值函数收敛到最优值 $V^*(s)$ 。当 (3-6) 使值函数收敛后，最优的策略 $\pi^*(s)$ 可以通过以下方式得到：

$$\pi^*(s) = \arg \max_a \left[F(s, a) + \gamma \sum_{s'} P(s' | s, a) V(s') \right] \quad (3-7)$$

策略迭代是一种交替进行策略评估 (Policy Evaluation, PE) 和策略改进过程 (Policy Improvement) 求解 BOE 的方法，其核心思想是从一个初始策略 π_0 开始，通过 PE 计算当前策略下每个状态的值函数，然后通过 PI 找到一个新的策略，不断重复这两个步骤直到策略收敛。最终收敛得到的策略函数为 $\pi^*(s)$ ，对应的值函数为 $V^*(s)$ PE 和 PI 的具体迭代方程如下：

$$\begin{aligned} \text{PE: 给定 } \pi_k, \quad V_{\pi_k}(s) &= F(s, \pi_k(s)) + \gamma \sum_{s'} P(s' | s, \pi_k(s)) V_{\pi_k}(s') \\ \text{PI: 给定 } V_{\pi_k}, \quad \pi_{k+1}(s) &= \arg \max_a \left[F(s, a) + \gamma \sum_{s'} P(s' | s, a) V_{\pi_k}(s') \right] \end{aligned} \quad (3-8)$$

可以看出无论是值迭代还是策略迭代，最终都是要得到一个最优值函数 $V^*(s)$ 和最优策略 $\pi^*(s)$ 。不同在于前者通过迭代方法直接更新值函数最终得到最优值函数后，再计算最优策略，后者通过不断通过不断改进策略最终得到最优策略后，再计算最优值函数。

Actor-Critic (AC) 本质上也是一种基于策略的方法，不同的是它结合了值迭代和策略迭代的的思想，同时学习策略和价值函数，而不是学习一个后计算另一个。这种结合使得 AC 方法在处理连续动作空间和大规模状态空间问题时，比传统的单独值迭代或策略迭代方法更具鲁棒性和适用性。”Actor” 和”Critic” 是 AC 方法的两个主要部分，分别用来逼近最优策略和最优值函数，一般用神经网络表示。即是在策略迭代的框架下，一方面使用一个神经网络对 PE 过程中

的值函数 $V_{\pi_k}(s)$ 进行逼近, 记为 $V(s, \omega)$ 。其中 ω 为神经网络的参数, 这部分神经网络记为 Critic 网络。Critic 网络的目标是估计每个状态的价值, 根据训练过程使用的 Loss 函数不同, 可以构建不同的 AC 算法。最常见的 AC 通常使用时序差分 (Temporal-Difference, TD) 进行逼近, 使用 TD 误差 (TD error) 作为 Loss 更新网络参数。TD error 定义为:

$$\delta_t = r_t + \gamma V(s_{t+1}, \omega) - V(s_t, \omega) \quad (3-9)$$

式中 r_t 表示 t 时刻获得的奖励。

损失函数定义为:

$$L_{\text{critic}}(\omega) = \frac{1}{2} \mathbb{E}[\delta^2] \quad (3-10)$$

另一方面, 使用另一个神经网络对 PI 过程的策略函数 $\pi(s)$ 进行逼近, 记为 $\pi(s, \theta)$ 。其中 θ 为神经网络的参数, 这部分神经网络记为 Actor 网络。Actor 网络的目标是生成一个用于选择动作的基于状态的策略, 进而使智能体达成实际问题的目标 (如最小化原本优化问题的代价函数)。当代价函数用值函数 V 表示时, 策略函数的损失函数可以表示为:

$$L_{\text{actor}}(\theta) = -\mathbb{E}[\log \pi(s_t, \theta) (r_t + \gamma V(s_{t+1}, \omega) - V(s_t, \omega))] \quad (3-11)$$

构造好神经网络及其损失函数后, 即可通过梯度下降等方法对损失函数进行优化, 逐步更新参数 ω 和 θ 使损失函数收敛。使用不同函数作为 Actor 和 Critic 网络的 Loss 结合不同迭代方式即可得到不同的 AC 算法, 如 TRPO, PPO, SAC 等。

综上所述, 只需要基于原优化问题的需求设计两个神经网络的 Loss 函数, 即可将值迭代和策略迭代过程转化为基于数据对神经网络进行更新的过程。只要这两个神经网络能够收敛, 即可同时得到最优值和最优策略。本章节在强化学习方面的研究都是以一般 Actor-Critic 方法为基础进行的, 即以式 (3-10)(3-11) 作为 Loss。下节将介绍如何通过 Actor-Critic 框架对机会约束优化问题进行求解。

3.4 基于模型的强化学习方法解机会约束优化问题

本节为本章的主要工作和创新部分, 主要在强化学习的框架下改进了一种机会约束优化问题的转化与求解方案。前面提到, 用 RL 解优化问题由于要先构造优化问题对应的 BOE, 强化学习可以直接解决的优化问题是无约束的优化问题。因此首先需要将带有机会约束的优化问题转化为无约束形式, 构建 BOE 后再用强化学习框架进行求解。将有约束优化问题处理成无约束优化问题的一

般方法是通过将硬约束转化为软约束，即通过适当的变形将约束转移到代价函数中，让代价函数具有相应约束的作用。常用的将硬约束处理称软约束的方法包括惩罚法^[87-88]和拉格朗日法^[89-90]，最近还有结合这两种方法的 SPIL 法^[91]。然而由于加入了约束部分的函数，上述提到的方法转化后的迭代过程都是使用数据进行梯度更新，收敛速度较慢。本研究在使用软约束处理优化问题中约束的同时，使用动态模型的梯度参与迭代过程，显著提高了收敛速度。

本研究主要使用 AC 框架作为强化学习求解算法。我们将这种处理机会约束优化问题的 AC 框架称为机会约束 AC 算法（Chance Constraint Actor-Critic, CCAC）。下面将通过问题描述、问题转化、以及如何通过 AC 框架求解转化后问题的顺序进行具体的算法介绍。

3.4.1 机会约束优化问题描述

为适合强化学习的符号习惯，我们重新表述机会约束优化问题为以下形式：

$$\begin{aligned} s_{t+1} &= f(s_t, a_t, \zeta_t), \quad \zeta_t \sim p(\zeta_t) \\ \Pr \left\{ \bigcap_{i=1}^N [h(s_{t+i}) \leq 0] \right\} &\geq 1 - \delta \end{aligned} \quad (3-12)$$

式中 t ——当前时间步；

$s_t \in \mathcal{S}$ ——系统在时刻 t 的状态及其状态约束集合；

$a_t \in \mathcal{A}$ ——系统在时刻 t 的输入及其输入约束集合；

$f(s_t, a_t, \zeta_t)$ ——环境模型函数；

ζ_t ——系统不确定性。

(3-12) 中约束的含义是：agent 在预测范围 N 中停留在安全范围的概率至少为 $1 - \delta$ ，简单起见本研究中只考虑单约束。代价函数为最大化无线时域内的累计奖励，优化问题定义如下：

$$\begin{aligned} \max_{\pi} J_r(\pi) &= \mathbb{E}_{s_0, \zeta} \left\{ \sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \right\} \\ \text{s.t. } p_s(\pi) &= \Pr \left\{ \bigcap_{t=1}^N [h(s_t) \leq 0] \right\} \geq 1 - \delta \\ s_{t+1} &= f(s_t, a_t, \zeta_t), \quad \zeta_t \sim p(\zeta_t) \end{aligned} \quad (3-13)$$

式中 π ——策略；
 $r(s_t, a_t)$ ——每一时刻的奖励函数；
 γ ——折扣因子，满足 $0 \leq \gamma \leq 1$ 。

3.4.2 机会约束优化问题处理

首先进行从机会约束到软约束的处理，我们使用罚函数的思想设计软约束。处理后的代价函数为：

$$\max_{\pi_k} J_{EP}(\pi_k) = J_r(\pi_k) - \frac{1}{2} b_k \max(1 - \delta - p_s(\pi_k), 0)^2 \quad (3-14)$$

式中 b_k ——设计为远大于 0 的权重系数，用以保证机会约束的满足。
 从处理后的代价函数可以看出：当机会约束满足的概率满足不小于设定概率的条件时，软约束不施加惩罚；当机会约束满足的概率小于设定概率时，软约束施加惩罚，且概率满足偏差越大这个惩罚越严重。这样在最大化代价的同时就可以同时考虑到了原机会约束。

3.4.3 机会约束优化问题求解

设 agent 的某个更新步下策略为 π ，采样数据中状态-动作数据记录为 (s, a) ，基于原优化问题构建 Actor-Critic 算法框架下需要的参数。定义值函数为：

$$Q^\pi(s, a) = \mathbb{E}_\xi \left\{ \sum_{t=0}^{\infty} \gamma^t r(s_t, a_t) \mid s_0 = s, a_0 = a \right\} \quad (3-15)$$

式中 $Q^\pi(s, a)$ ——动作值函数。

与强化学习理论中的值函数 V 类似，二者关系为：

$$V(s) = \sum_a Q(s, a) \pi(a \mid s) \quad (3-16)$$

利用 $Q^\pi(s, a)$ 的定义，原优化问题的代价函数可以改写为以下 N 步的形式：

$$J_r(\pi) = \mathbb{E}_{s_0, \xi} \left\{ \sum_{t=0}^{N-1} \gamma^t r(s_t, a_t) + \gamma^N Q^\pi(s_N, a_N) \right\} \quad (3-17)$$

在 Actor-Critic 中，值函数和策略函数都被参数化，用两个神经网络表示，即

$$Q(s, a) \cong Q(s, a; \omega) \quad (3-18)$$

$$a \cong \pi(s; \theta) \quad (3-19)$$

其中 Critic 部分损失函数定义为 Q 网络的输出值与实际采样值偏差平方的期望。

$$\begin{aligned}
 J_Q &= \mathbb{E}_{s_0, \xi} \left\{ \frac{1}{2} (Q_{target} - Q(s_0, \mathbf{a}_0; \omega^k))^2 \right\} \\
 Q_{target} &= \sum_{t=0}^{N-1} \gamma^t r(s_t, \mathbf{a}_t) + \gamma^N Q(s_N, \mathbf{a}_N; \omega^k)
 \end{aligned} \tag{3-20}$$

Actor 网络的损失函数直接使用带有软约束的原优化问题代价函数 (3-14)。

在神经网络更新过程中，对于 Critic 网络，考虑其梯度公式 (3-21)：

$$\nabla_{\omega} J_Q = \mathbb{E}_{s_0, \xi} \left\{ (Q(s_0, \mathbf{a}_0; \omega^k) - Q_{target}) \frac{\partial Q(s_0, \mathbf{a}_0; \omega^k)}{\partial \omega} \right\} \tag{3-21}$$

由于其梯度与状态和动作的梯度无关，可以直接使用数据进行网络更新。

对于 Actor 网络，考虑其梯度更新公式 (3-22)：

$$\nabla_{\theta} J_{EP} = \begin{cases} \nabla_{\theta} J_r & p_s \geq 1 - \delta \\ \nabla_{\theta} J_r + b_k(1 - \delta - p_s) \nabla_{\theta} p_s & p_s \leq 1 - \delta \end{cases} \tag{3-22}$$

对于 J_r 部分，根据式 (3-13) 的定义，其由 s_t 和 $\mathbf{a}_t$ 构成，可以对 $r(s, \mathbf{a})$ 进行梯度求取直接得到。对于软约束部分，只有 p_s 是变量，在采样过程中，我们设采样 M 条轨迹，同时设这 M 条轨迹中满足 (3-12) 中机会约束的轨迹有 m 条，可以得到 $p_s \approx \frac{m}{M}$ 。我们将 M 固定， m 是通过将采样序列 $(s_t, \mathbf{a}_t)$ 代入机会约束方程中统计出来的，其也由 s_t 和 $\mathbf{a}_t$ 组成。因此，Actor 网络损失函数的梯度也只与 s_t 和 $\mathbf{a}_t$ 有关。

无模型的 RL 更新公式一般是通过数值进行梯度更新，如使用采样点拟合 $\nabla_{\theta} p_s$ 后基于 Critic 网络对 Actor 网络参数进行更新。这样得到的梯度方向会受到函数拟合所导致的偏差，使收敛速度减慢。相比之下，基于模型的方法可以利用系统动态信息直接计算梯度，从而在训练过程中减少不确定性对收敛速度的负面影响。在本研究中我们直接使用系统的模型辅助代价函数中梯度的求取，这样可以最大程度避免梯度的偏差，保证使用的梯度是代价函数的真实梯度，继而加快收敛速度。梯度求取公式为：

$$\nabla_{\theta} p_s = \frac{\partial p_s}{\partial h(s)} \frac{\partial h(s)}{\partial s} \frac{\partial s}{\partial \theta} \tag{3-23}$$

在文献 [88] 中，在求软约束梯度 $\nabla_{\theta} J_{EP}$ 时，使用拟合梯度的方式不直接求 $\nabla_{\theta} p_s$ ，而是使用和其梯度方向具有正相关性的新梯度 $\nabla_{\theta} J_c$ 进行替代。 J_c 的构造来自另一种处理机会约束的方法：Bool's Approximation。其将每一预测时刻约束满足与否的情况用一个阶跃函数表示，之后用预测时域范围内这些阶跃函数

的求和的期望值作为代价函数，记为 J_c ，通过概率不等式可以得到 p_s 和 J_c 的关系。具体推导过程见式 (3-24) 到 (3-26)

$$c(s_t, a_t, s_{t+1}) = \begin{cases} 0, & h(s_{t+1}) \leq 0 \\ 1, & h(s_{t+1}) \geq 0 \end{cases} \quad (3-24)$$

$$J_c(\pi) = \mathbb{E}_{s_0, \xi} \left\{ \sum_{t=0}^{N-1} c(s_t, a_t, s_{t+1}) \right\} \quad (3-25)$$

$$\begin{aligned} p_s(\pi) &= \Pr \left\{ \bigcap_{t=1}^N [h(s_t) \leq 0] \right\} \\ &\geq 1 - \sum_{t=1}^N \Pr\{h(s_t) \geq 0\} \\ &= 1 - J_c(\pi) \end{aligned} \quad (3-26)$$

文献 [88] 根据式 (3-26) 发现 J_c 减小将会导致 p_s 上升，因此使用 $-\nabla_{\theta} J_c$ 来代替 $\nabla_{\theta} p_s$ ，前者比起后者更容易求取。

然而在实现过程中，我们发现两个问题，第一个问题是，在采样过程中，由于已经有了状态转移模型，因此直接用 pytorch 中的 backward 函数可以直接对 $\nabla_{\theta} p_s$ 进行求取。第二个问题是，经过对文献 [88] 的用 $-\nabla_{\theta} J_c$ 代替 $\nabla_{\theta} p_s$ 进行梯度更新的算法进行复现后，发现其结果并不收敛，即策略迭代下机会约束的满足概率并没有保持在设定概率附近。下节实验部分展示了文献 [88] 算法的效果，并添加了使用状态转移模型对 $\nabla_{\theta} p_s$ 直接进行求取的实验结果。

3.5 实验结果

为了验证本文所提出算法在求解机会约束优化问题中的可行性与有效性，我们选取典型随机系统——小车跟随（Car-Following）问题进行了测试实验。该问题在智能驾驶与自动控制领域中具有明确的物理意义，既包含性能优化目标，又天然伴随着安全约束。

实验场景如图 3-1 所示。假设前车以速度 v_f 匀速行驶，后车需通过自身加速度实现对前车的跟随。我们的控制目标是在保证两车间距以不低于给定的概率保持在设定范围内，同时尽可能提高后车的行驶速度，从而在安全性和效率之间取得平衡。由于系统中存在外界扰动，安全约束并不能被严格保证，所以需要通过机会约束的形式对安全性进行概率层面的刻画。

所有实验均在 Python 环境下完成，并使用 PyTorch 深度学习框架训练神经

网络。所有实验均在配备 Intel(R) Core(TM) i7-8700 CPU @ 3.20 GHz 的计算机上完成，软件环境为 Python 3.9.21 与 PyTorch 2.5.1。

3.5.1 系统模型与问题建模

小车的随机动态模型定义如下：

$$\begin{aligned} \mathbf{s}_{t+1} &= \mathbf{A}\mathbf{s}_t + \mathbf{B}\mathbf{a}_t + \mathbf{D}\boldsymbol{\xi} \\ \mathbf{A} &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -T & T & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} T \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{D} = \begin{bmatrix} 0 \\ 0 \\ T \end{bmatrix} \end{aligned} \quad (3-27)$$

系统状态向量为 $\mathbf{s} = [\mathbf{v}_e, \mathbf{v}_f, \epsilon]^\top$ ，其中 $\mathbf{v}_e$ 代表跟随车辆的速度， $\mathbf{v}_f$ 代表被跟随车辆的速度， ϵ 代表两车纵向间距。其中，前车速度 $\mathbf{v}_f$ 被假设为常数。扰动项 $\boldsymbol{\xi}_t$ 用于刻画未建模动态及外界不确定性因素，其服从均值为 0 方差为 1 的高斯分布，且截断在区间 $(-5, 5)$ 内。控制输入 $\mathbf{a}_t$ 表示后车的纵向加速度，且受到物理约束 $\mathbf{a}_t \in (-4, 3)$ ，时间离散步长设定为 $T = 0.1$ ，该参数在保证系统动态近似精度的同时，也兼顾了数值计算的稳定性。

基于上述建模假设，机会约束优化问题可以表述为式 (3-28) 的形式。

$$\begin{aligned} \max_{\pi} \quad & \mathbb{E}_{\mathbf{s}_0, \boldsymbol{\xi}} \left\{ \sum_{t=0}^{\infty} \gamma^t (0.2\mathbf{v}_{e,t} - 0.05\epsilon_t) \right\} \\ \text{s.t.} \quad & \Pr \left\{ \bigcap_{t=1}^N [\epsilon_t \geq 2] \right\} \geq 1 - \delta \\ & \mathbf{s}_{t+1} = \mathbf{A}\mathbf{s}_t + \mathbf{B}\mathbf{a}_t + \mathbf{D}\boldsymbol{\xi}_t \end{aligned} \quad (3-28)$$

该目标函数在期望意义下最大化累计回报，其中回报函数由车辆速度项和车间距离惩罚项构成。速度项鼓励后车尽可能以较高速度行驶，而距离惩罚项则抑制过大的跟车间距，从而避免系统过于保守。机会约束要求在给定时间窗口内，车辆间距不小于 2 米的概率不低于 $1 - \delta$ 。对应实际驾驶场景的安全需求。

实验设定机会约束违背概率 $\delta = 0.1$ ，损失函数折扣因子 $\gamma = 0.98$ ，Critic 网络和 Actor 网络的更新步长分别为 $1e^{-5}$ 和 $2e^{-4}$ 。防止梯度过大导致训练不稳定。

训练过程中共采集 2700 组数据，每 30 组数据组成一个 episode，共训练 90 个回合。在每个回合中，通过多次随机采样对机会约束满足概率进行估计，从而减小随机扰动对概率评估带来的偏差。

为了验证不同梯度设计方式在机会约束优化中的效果，本文分别实现了以下两种算法：





图 3-1 小车跟随场景


- 直接利用反向传播计算 $\nabla_{\theta} p_s$ ，并将其作为策略参数更新的梯度；
- 采用文献 [88] 中提出的替代梯度方法，即用 $-\nabla_{\theta} J_c$ 对策略参数进行更新。

3.5.2 实验结果与对比分析

两种算法的训练结果分别如图 3-2 和图 3-3 所示。


 图 3-2 $\nabla_{\theta} p_s$ 更新结果

从图 3-2 可以看出，在采用 $\nabla_{\theta} p_s$ 进行梯度更新时，实际回报与原始代价 J_r 随训练逐步收敛，且机会约束满足概率 p_s 能稳定收敛至预设阈值附近，表明该方法能够在兼顾性能优化的同时有效满足安全概率约束。相比之下，使用 $-\nabla_{\theta} J_c$


 图 3-3 $-\nabla_{\theta} J_c$ 更新结果

作为替代梯度时，尽管原始代价有所下降，但如图 3-3(b) 所示，机会约束满足概率始终未能收敛，并在训练过程中出现明显震荡，说明该梯度难以准确反映约束概率对策略参数的影响。

需要指出的是，直接梯度方法下概率曲线仍存在一定波动，主要由于采样数量有限及随机扰动影响所致，在统计意义上是可以接受的。

为进一步验证算法的稳定性与鲁棒性，本文在不同预设概率条件下进行了多组对比实验。表 3-1 汇总了在不同预设概率 p 下，采用 $\nabla_{\theta} p_s$ 进行梯度更新时的控制效果。其中实际概率为 20 次独立实验结果的平均值。可以看到，对于不同的预设概率水平，实际机会约束满足概率均能够稳定收敛到目标值附近，且标准差保持在较小范围内，进一步验证了该方法在随机环境下的可靠性。

表 3-1 不同预设概率下控制效果

预设概率	实际概率	标准差
0.9	0.9016	0.0046
0.85	0.8449	0.0051
0.8	0.8122	0.0093

3.5.3 梯度范数与收敛分析

为比较两种算法的优化特性，本文记录了训练过程中策略参数梯度二范数的变化。如图 3-4 和图 3-5 绿色折线所示，采用 $\nabla_{\theta} p_s$ 更新时，梯度范数随训练逐步减小并趋于稳定，表明参数能够收敛；而使用 $-\nabla_{\theta} J_c$ 更新时，梯度范数未出现明显下降，参数更新呈现震荡，难以收敛。这说明基于软约束的替代梯度难以准确反映机会约束对策略参数的实际影响。

综合来看，直接对机会约束满足概率进行梯度建模与反向传播，在约束满足效果和优化稳定性方面均优于基于软约束的替代梯度方法。




图 3-4 $\nabla_{\theta} p_s$ 更新梯度记录




图 3-5 $-\nabla_{\theta} J_c$ 更新梯度记录

3.6 本章小结

在本章中，我们首先在小节 3.1 和小节 3.2 介绍了机会约束优化问题和强化学习的基本原理。并简单介绍了强化学习的常用框架之一——Actor-Critic。之后在小节 3.3 介绍了本章的主要工作：从机会约束优化问题出发，经过软约束的设计，BOE 构建，以及在 Actor-Critic 的框架下对梯度更新的设计与验证实现对机会约束优化问题的求解。提出 CCAC 算法存在的问题并加以改进。最后通过实验验证并分析了算法对于机会约束优化问题求解的有效性，以及改进的合理性。

第4章 基于随机模型预测控制的机会约束优化问题求解

4.1 引言

本章节主要介绍在随机模型预测控制框架下求解机会约束优化问题的算法。重点在于在已知约束条件下的滚动时域优化与控制律设计。首先介绍了模型预测控制问题的基本框架。然后对基于随机管的随机模型预测控制算法^[61]进行研究，了解模型预测控制下求解机会约束优化问题的一般思路。之后提出其造成机会约束实际满足概率远大于设定概率，控制效果过于保守的现象，并对其原因进行量化分析，最后基于分析结果提出了使用扰动变量的分布函数处理机会约束的方法，降低了机会约束实际满足概率与设定概率的偏差，降低了控制的保守性，并通过仿真示例展示了所提算法的有效性。

4.2 模型预测控制基本框架

模型预测控制（Model Predictive Control, MPC）是一类考虑系统动态模型的基于优化的控制策略。其核心是通过在每一时刻求解一个有限时域最优控制问题以得到每时刻的控制量，实现对系统的动态控制^[92]。相较于PID，LQR等经典控制方法，MPC具有能够显式处理约束，处理线性和非线性系统、MIMO问题，同时具有一定鲁棒性的优点。MPC主体框架可以分为预测模型，滚动优化和反馈校正三方面，下面将对MPC的基本框架进行简要介绍。

4.2.1 模型预测控制的预测模型

MPC是基于模型的控制方法，一个好的预测模型是实现有效MPC控制的基础。预测模型能够通过系统的当前状态和未来控制变量序列预测系统的未来状态，继而可以对未来系统状态的控制进行有效研究。预测模型可以从系统的动态模型推导而来，MPC可用的动态模型的形式不作限制，为方便推导计算常用状态空间方程形式表示，下面介绍从动态模型得到预测模型的一般流程。

状态方程形式的线性系统模型一般定义如下（非线性系统一般先通过泰勒展开等线性化方法得到状态方程形式的线性系统表达）：

$$\begin{aligned}\dot{\mathbf{x}} &= \mathbf{A}\mathbf{x} + \mathbf{B}\mathbf{u} \\ \mathbf{y} &= \mathbf{C}\mathbf{x} + \mathbf{D}\mathbf{u}\end{aligned}\quad (4-1)$$

(4-1) 是连续系统的状态方程。由于计算机的运算本质上都是离散的，因此还需要将系统进行离散化得到式 (4-2) 的形式以方便后续的代码编写（常用欧拉法或前向差分，后向差分，双线性变换等方法实现连续系统的离散化工作）。

$$\begin{aligned}\mathbf{x}_{k+1} &= \mathbf{A}_d\mathbf{x}_k + \mathbf{B}_d\mathbf{u}_k \\ \mathbf{y}_k &= \mathbf{C}_d\mathbf{x}_k + \mathbf{D}_d\mathbf{u}_k\end{aligned}\quad (4-2)$$

系数 $\mathbf{A}_d, \mathbf{B}_d, \mathbf{C}_d, \mathbf{D}_d$ 为系统 (4-1) 离散化后对应离散系统的矩阵参数，具体计算公式见表4-1。有了离散状态方程后，可以基于当前状态和未来控制量预测未来的系统状态：

$$\begin{aligned}\mathbf{x}_{k+1} &= \mathbf{A}_d\mathbf{x}_k + \mathbf{B}_d\mathbf{u}_k \\ \mathbf{x}_{k+2} &= \mathbf{A}_d\mathbf{x}_{k+1} + \mathbf{B}_d\mathbf{u}_{k+1} \\ &= \mathbf{A}_d(\mathbf{A}_d\mathbf{x}_k + \mathbf{B}_d\mathbf{u}_k) + \mathbf{B}_d\mathbf{u}_{k+1} \\ &= \mathbf{A}_d^2\mathbf{x}_k + \mathbf{A}_d\mathbf{B}_d\mathbf{u}_k + \mathbf{B}_d\mathbf{u}_{k+1} \\ \mathbf{x}_{k+3} &= \mathbf{A}_d\mathbf{x}_{k+2} + \mathbf{B}_d\mathbf{u}_{k+2} \\ &= \mathbf{A}_d^3\mathbf{x}_k + \mathbf{A}_d^2\mathbf{B}_d\mathbf{u}_k + \mathbf{A}_d\mathbf{B}_d\mathbf{u}_{k+1} + \mathbf{B}_d\mathbf{u}_{k+2} \\ &\vdots \\ \mathbf{x}_{k+N_p} &= \mathbf{A}_d^{N_p}\mathbf{x}_k + \mathbf{A}_d^{N_p-1}\mathbf{B}_d\mathbf{u}_k + \cdots + \mathbf{B}_d\mathbf{u}_{k+N_p-1}\end{aligned}\quad (4-3)$$

式中 N_p ——预测时域，表示对未来进行预测的时间长度。

上式 (4-3) 可简写为以下向量形式：

$$\mathbf{X} = \mathbf{F}\mathbf{X}_0 + \Phi\mathbf{U}\quad (4-4)$$

其中

表 4-1 不同方法下离散系统参数计算公式

参数	欧拉法	后向差分	双线性变换
$\mathbf{A}_d$	$\mathbf{I} + \mathbf{A} * \Delta t$	$(\mathbf{I} - \mathbf{A} * \Delta t)^{-1}$	$(\mathbf{I} - \frac{\mathbf{A} * \Delta t}{2})^{-1}(\mathbf{I} + \frac{\mathbf{A} * \Delta t}{2})$
$\mathbf{B}_d$	$\mathbf{B} * \Delta t$	$(\mathbf{I} - \mathbf{A} * \Delta t)^{-1}\mathbf{B} * \Delta t$	$(\mathbf{I} - \frac{\mathbf{A} * \Delta t}{2})^{-1}\mathbf{B} * \Delta t$
$\mathbf{C}_d$	$\mathbf{C}$	$\mathbf{C} * (\mathbf{I} - \mathbf{A} * \Delta t)^{-1}$	$\mathbf{C}(\mathbf{I} - \frac{\mathbf{A} * \Delta t}{2})^{-1}$
$\mathbf{D}_d$	$\mathbf{D}$	$\mathbf{D} + \mathbf{C} * (\mathbf{I} - \mathbf{A} * \Delta t)^{-1}\mathbf{B} * \Delta t$	$\mathbf{D} + \mathbf{C}(\mathbf{I} - \frac{\mathbf{A} * \Delta t}{2})^{-1}\frac{\mathbf{B} * \Delta t}{2}$

$$\begin{aligned}
 \mathbf{X} &= [\mathbf{x}_{k+1}, \mathbf{x}_{k+2}, \dots, \mathbf{x}_{k+N_p}]^\top \\
 \mathbf{X}_0 &= \mathbf{x}_k \\
 \mathbf{U} &= [\mathbf{u}_k, \mathbf{u}_{k+1}, \dots, \mathbf{u}_{k+N_p-1}]^\top \\
 \mathbf{F} &= [\mathbf{A}_d, \mathbf{A}_d^2, \dots, \mathbf{A}_d^{N_p}]^\top \\
 \Phi &= \begin{bmatrix} \mathbf{B}_d & \mathbf{0} & \dots & \mathbf{0} \\ \mathbf{A}_d \mathbf{B}_d & \mathbf{B}_d & \dots & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{A}_d^{N_p-1} \mathbf{B}_d & \mathbf{A}_d^{N_p-2} \mathbf{B}_d & \dots & \mathbf{B}_d \end{bmatrix}
 \end{aligned} \tag{4-5}$$

综合式 (4-2) 可以得到预测输出量 $\mathbf{Y}$ 的表达式如下：

$$\mathbf{Y} = \mathbf{C}_d \mathbf{F} \mathbf{X}_0 + \mathbf{C}_d \Phi \mathbf{U} \tag{4-6}$$

至此，我们基于系统的动态方程得到了可用的预测模型。下一节将基于预测模型介绍滚动优化方面的内容。

4.2.2 模型预测控制的滚动优化

与一般离散系统最优控制算法不同，MPC 中优化问题的目标函数不是一个固定的全局目标，而是通过“滚动”的形式，在每一时刻考虑一个有限时域的局部目标。通过解决每个局部问题实现对整体问题的求解。

具体控制流程如下：在每一个采样时刻，MPC 控制器都会基于当前时刻的系统状态根据预测时域范围内需要的性能指标构建有限时域优化问题（目标函数和相关约束），并通过求解这个优化问题得到一个有限的最优控制序列。即在每一个采样时刻下，MPC 只考虑从该时刻开始到未来有限时域的时间段的优化性能指标的满足情况。而到下一个采样时刻这个时间段会向后“滚动”，下面用一个具体的跟踪问题简单展示滚动优化的整体流程。

以坐标原点 $\mathbf{0}$ 为目标点的轨迹规划问题为例。我们基于上一节中式 (4-2)(4-3)(4-5) 构造优化问题。为了简化问题描述，我们假设输出 $\mathbf{y}_k = \mathbf{x}_k$ ，参考点 $\mathbf{R} = \mathbf{0}$ ，定义 k 时刻下对第 $k+i$ 时刻的状态预测为 $\mathbf{x}_{k+i|k}$ ， k 时刻问题中将 $k+i$ 时刻的输入记为 $\mathbf{u}_{k+i|k}$ 。依此构造二次型的代价函数如下：

$$\min_{\mathbf{u}} J = \sum_{i=0}^{N_p-1} \left(\mathbf{x}_{k+i|k}^\top \mathbf{Q} \mathbf{x}_{k+i|k} + \mathbf{u}_{k+i|k}^\top \mathbf{R} \mathbf{u}_{k+i|k} \right) + \mathbf{x}_{k+N_p|k}^\top \mathbf{F} \mathbf{x}_{k+N_p|k} \tag{4-7}$$

式中 $\mathbf{Q}$ ——基于性能指标选取的状态权重矩阵；
 $\mathbf{R}$ ——基于性能指标选取的输入权重矩阵；
 $\mathbf{F}$ ——为满足 MPC 控制性质理论保证条件而引入的终端约束权重矩阵。

结合式 (4-3) 可以将优化问题代价函数转化为只与 k 时刻初始状态 $\mathbf{x}_k$ 和控制序列 $\{\mathbf{u}_{k+i|k}\}, i = 0, \dots, N_p - 1$ 有关的多项式。约束方面这里出于简单考虑只考虑输入约束 $\mathbf{u} \in \mathcal{U}$ 。至此可以构造 k 时刻的有限时域优化问题 (4-7):

$$\begin{aligned} \min_{\mathbf{u}} J &= \sum_{i=0}^{N_p-1} \left(\mathbf{x}_{k+i|k}^\top \mathbf{Q} \mathbf{x}_{k+i|k} + \mathbf{u}_{k+i|k}^\top \mathbf{R} \mathbf{u}_{k+i|k} \right) + \mathbf{x}_{k+N_p|k}^\top \mathbf{F} \mathbf{x}_{k+N_p|k} \\ \text{s.t. } &\mathbf{u} \in \mathcal{U} \end{aligned} \quad (4-8)$$

由于 k 时刻初始状态已知，求解这个优化问题可以得到一个开始于 k 时刻的最优控制序列 $\{\mathbf{u}_{k+i|k}\}, i = 0, \dots, N_p - 1$ 。之后将该控制序列的第一个元素 $\mathbf{u}_{k|k}$ 与当前状态 $\mathbf{x}_k$ 代入系统方程 (4-2)，可以得到下一时刻的系统状态 $\mathbf{x}_{k+1}$ （预测模型状态和实际系统状态的偏差由下一节介绍的反馈校正部分解决），并进行新一轮有限时域优化问题的构造与求解。

滚动优化策略的优势在于：由于在每个时间步上重新计算了控制策略，滚动优化的控制具有更好的实时性，其不需要一次性求解整体的优化问题，而是每次求解一个局部的优化问题，降低了计算复杂度。此外，由于每一时刻的优化问题都基于当前时刻的状态构造，且只考虑一定时间范围内的状态和行为，这使控制器具有一定的反馈性质，同时可以对外部扰动有一定的鲁棒性。

除了滚动优化外，反馈校正也是保证 MPC 控制器具有一定的鲁棒性，下节将进行对反馈控制的介绍。

4.2.3 模型预测控制的反馈校正

反馈校正机制是 MPC 解决模型失配，抵抗外部干扰等不确定性影响的重要组成部分。其主要作用是保证模型的预测输出（状态）与实际系统的输出（状态）的一致性。下面对其基本原理进行介绍。

MPC 中一种经典的反馈校正方法是通过输出误差进行校正补偿，即将当前时刻的预测误差（实际输出-预测输出）加到未来时刻的预测输出上，进而使未来的预测输出更接近未来的实际输出。由于在上一小节的进行 MPC 问题的简化定义时设计了系统的输出即为系统状态，因此本节介绍的反馈校正也可以看作通过当前时刻的状态预测误差（实际状态-预测状态）来实现。具体校正公式

如下：

$$\begin{aligned} \mathbf{x}_{k+i|k}^{\text{correct}} &= \mathbf{x}_{k+i|k}^{\text{predicted}} + \mathbf{H}\mathbf{e}_k \\ \mathbf{e}_k &= \mathbf{x}_k^{\text{actual}} - \mathbf{x}_{k|k-1}^{\text{predicted}} \end{aligned} \quad (4-9)$$

式中 correct ——上标，表示校正量；

predicted ——上标，表示预测量；

actual ——上标，表示实际量；

$\mathbf{H}$ ——补偿增益矩阵，通常取 $\mathbf{H} = [1, \alpha, \alpha^2, \dots, \alpha^N]^\top$ ；

α ——衰减系数，满足 $0 \leq \alpha \leq 1$ ；

N ——状态维度，满足 $N = \dim(\mathbf{x}_k)$ 。

此外，还可以通过扩展卡尔曼滤波、无界卡尔曼滤波、粒子滤波等状态估计方法进行系统的状态估计更新。

虽然由于滚动优化和反馈校正的存在，MPC 对模型误差和外界干扰等影响具有一定的鲁棒性。然而这样的鲁棒性质一方面没有严格的理论保证，另一方面其抗干扰的效果有限，对于较为强烈的外部影响，一般 MPC 框架自带的鲁棒效果不足以完全保证控制的稳定性和有效性。为了解决这个问题，人们提出了一种特殊的 MPC 框架：随机 MPC，其在具有较为严格理论保证的条件下，比一般的 MPC 具有更高的处理不确定性影响的能力。下面将对随机 MPC 理论进行具体的介绍。

4.3 基于随机管的随机模型预测控制算法

模型预测控制问题的建立首先需要定义系统和优化问题。随机模型预测控制解决的也是 CCOP。

系统方面：考虑有状态量 $\mathbf{x}_k$ ，输入量 $\mathbf{u}_k$ ，扰动量 $\mathbf{w}_k$ 的线性时不变（Linear and Time-invariant, LTI）受扰动系统：

$$\mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k + \mathbf{B}_u\mathbf{u}_k + \mathbf{B}_w\mathbf{w}_k \quad (4-10)$$

其中 $\mathbf{x} \in \mathbb{R}^{n_x}$, $\mathbf{u} \in \mathbb{R}^{n_u}$, $\mathbf{w} \in \mathbb{R}^{n_w}$ ，扰动 $\mathbf{w}_k$ 为零均值的独立同分布随机变量并满足

$$\mathbf{w}_k \in \mathcal{E}(\mathbf{W}, \alpha_k) = \{\mathbf{w} \mid \mathbf{w}^\top \mathbf{W} \mathbf{w} \leq \alpha_k\} \quad (4-11)$$

此处的 $\alpha_k, k = 0, 1, \dots$ 也是独立同分布的有界随机变量，其分布函数已知：

$$F_\alpha(a) = \Pr(\alpha_k \leq a) \quad (4-12)$$

其中 a 是有界的标量且 $a \in [0, \bar{a}]$, $0 \leq \bar{a} \leq \infty$ 。

优化问题方面：随机模型预测控制算法处理是 MPC 形式的 CCOP，为简便起见这里只考虑单机会约束的问题。多约束情况取约束的交集即可。优化问题形式如下：

$$\begin{aligned} \min_{\mathbf{v}_k} J_k &= \sum_{i=0}^{\infty} \mathbb{E}_k (\mathbf{x}_{k+i}^\top \mathbf{Q} \mathbf{x}_{k+i} + \mathbf{u}_{k+i}^\top \mathbf{R} \mathbf{u}_{k+i}) \\ \text{s.t. } \Pr(\mathbf{g}^\top \mathbf{x} \leq h) &\geq p, \quad p \geq 0.5 \end{aligned} \quad (4-13)$$

式中 $\mathbf{Q}$ ——状态代价的权重矩阵；

$\mathbf{R}$ ——输入代价的权重矩阵；

p ——设定的机会约束满足概率。

即要求将优化问题 (4-13) 的解代入到受扰动系统 (4-10) 后，考虑所有扰动可能造成的影响，机会约束能够以不小于 p 的概率被满足。我们将系统方程 (4-10) 中的状态 $\mathbf{x}_k$ 分解为 (4-14) 中标称状态 $\mathbf{z}_k$ 与偏差量 $\mathbf{e}_k$ 的和的形式。其中 $\mathbf{z}_k$ 为 $\mathbf{x}_k$ 中完全确定的部分， $\mathbf{e}_k$ 为 $\mathbf{x}_k$ 中完全随机的部分。同时将控制律定义为 (4-15) 的状态反馈形式。

$$\mathbf{x}_k = \mathbf{z}_k + \mathbf{e}_k \quad (4-14)$$

$$\mathbf{u}_k = \mathbf{K} \mathbf{x}_k + \mathbf{c}_k \quad (4-15)$$

式中 $\mathbf{K}$ ——通过 LQR 方法得到的反馈系数；

$\mathbf{c}_k$ ——优化变量。

联立 (4-10)(4-14)(4-15) 可以得到 $\mathbf{e}_k$ 和 $\mathbf{z}_k$ 的迭代方程，分别为：

$$\mathbf{z}_{k+1} = \Phi \mathbf{z}_k + \mathbf{B}_u \mathbf{c}_k \quad (4-16)$$

$$\mathbf{e}_{k+1} = \Phi \mathbf{e}_k + \mathbf{B}_w \mathbf{w}_k \quad (4-17)$$

由于反馈系数 $\mathbf{K}$ 由 LQR 方法得到，根据 LQR 理论， $\Phi = \mathbf{A} - \mathbf{B}_u \mathbf{K}$ 是渐近稳定的。根据 (4-16) 和 (4-17) 可以看到，标称状态的状态转移过程只与上一时刻的标称状态以及控制量 $\mathbf{c}_k$ 有关，偏差量的状态转移过程只与上一时刻的偏差量以及扰动量 $\mathbf{w}_k$ 有关。MPC 问题一般认为初始状态已知，即 $\mathbf{x}_0 = \mathbf{z}_0$, $\mathbf{e}_0 = \mathbf{0}$ ，因此根据 (4-16) 和 (4-17) 进行状态转移时，每一时刻的标称状态 $\mathbf{z}_k$ 完全确定，每一时刻的偏差量 $\mathbf{e}_k$ 完全随机，这符合前面将 $\mathbf{x}_k$ 分解成 $\mathbf{z}_k$ 和 $\mathbf{e}_k$ 的假设条件。

对于 MPC 问题，每一时刻 k 需要考虑后面 N 个预测时刻。记 k 时刻下 MPC 问题中在预测时刻 $k+i$ 时刻的实际状态，标称状态和偏差量分别为

$\mathbf{x}_{k+i|k}, \mathbf{z}_{k+i|k}, \mathbf{e}_{k+i|k}, i = 1, \dots, N$ 。STMPC 算法主要包括两个部分^[61]：离线根据已知的不确定性分布信息进行随机管的计算，以及在线根据随机管的概率条件将机会约束处理成为确定性约束，并用确定 MPC 求解处理后的问题。下面对 STMPC 算法进行简要研究。

4.3.1 管随机模型预测控制离线部分

基于受扰动系统已知条件 (4-10)-(4-12) 与状态分解后的迭代方程 (4-17)，可以将每一时刻偏差量 $\mathbf{e}_k$ 所在集合表示为以下椭圆形式。

$$\mathcal{E}(\mathbf{V}, \beta) = \{\mathbf{e} \mid \mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \beta\}, \mathbf{V} = \mathbf{V}^\top \succ 0 \quad (4-18)$$

上述集合表示形式的理论依据基于以下四个式子：

$$\beta_{i+1} = \lambda \beta_i + \alpha_i \quad (4-19)$$

$$\mathbf{V}^{-1} - \frac{1}{\lambda} \Phi \mathbf{V}^{-1} \Phi^\top - \mathbf{B}_w \mathbf{W}^{-1} \mathbf{B}_w^\top \succeq 0 \quad (4-20)$$

$$\max_{\mathbf{e} \in \mathcal{E}(\mathbf{V}, \beta_i), \mathbf{w} \in \mathcal{E}(\mathbf{W}, \alpha_i)} (\Phi \mathbf{e} + \mathbf{B}_w \mathbf{w})^\top \mathbf{V} (\Phi \mathbf{e} + \mathbf{B}_w \mathbf{w}) \leq \beta_{i+1} \quad (4-21)$$

$$(\mathbf{V}^{-1}, \lambda) = \arg \min_{\mathbf{V}^{-1}, \lambda} \frac{1}{1 - \lambda} \mathbf{g}^\top \mathbf{V} \mathbf{g} \quad (4-22)$$

其中 $\beta_0 = 0$ ，式 (4-21) 保证当 i 时刻的偏差量满足条件 (4-18) 时， $i + 1$ 时刻的偏差量也满足条件 (4-18)。式 (4-19)，(4-20) 可以保证不等式 (4-21) 的成立。(4-19)，(4-20) 中的参数 $\lambda, \mathbf{V}$ 通过以式 (4-20) 为约束的半定规划 (4-22) 求解得到。

β_i 是一个只与 α_i 相关的离散随机序列，由于 (4-19) 的线性形式， β_i 的概率分布函数可以用卷积积分 (4-23) 得到，并通过离散化将卷积积分转化成了更方便计算的矩阵乘积形式 (4-25)。

$$F_{\beta_{i+1}}(x) = \lambda \int_0^{\frac{\bar{\beta}}{\lambda}} F_{\beta_i}(y) f_\alpha(x - \lambda y) dy \quad (4-23)$$

$$0 = x_0 \leq x_1 \leq \dots \leq x_\rho = \bar{\beta} \quad (4-24)$$

$$\pi_{i+1} = \mathbf{P} \pi_i \quad (4-25)$$

式中 $\bar{\beta}$ ——根据式 (4-19) 推出的 β 值的上确界, 满足 $\bar{\beta} = \frac{\bar{\alpha}}{1-\lambda}$;
 x_j ——按照式 (4-24) 将区间 $[0, \bar{\beta}]$ 等间隔划分为 $\rho + 1$ 份后的第 j 个端点, $j = 0, \dots, \rho$;
 P ——卷积积分离散化后得到的矩阵;
 π_i ——随机变量 β_i 的分布函数离散形式;
 $\pi_{i,j}$ ——离散分布中对应端点 x_j 的取值, 满足 $\pi_{i,j} = F_{\beta_i}(x_j)$ 。

使用序列 π_i 即可构造一套显示偏差量置信度的随机管。定义以下两个函数:

$$\text{ind}(\pi_i, p) = \min j, j \in \{j : \pi_{i,j} \geq p\} \quad (4-26)$$

$$\mathbf{b}(\pi_i, p) = \mathbf{x}_j, j = \text{ind}(\pi_i, p) \quad (4-27)$$

$\text{ind}(\pi_i, p)$ 的作用是提取置信度为 p 的索引, 其输入为第 i 个预测时刻的 β_i 的分布序列 π_i 与置信度 p , 输出为满足 $\pi_{i,j} \geq p$ 的最小索引 j ; $\mathbf{b}(\pi_i, p)$ 的作用是得到 $\text{ind}(\pi_i, p)$ 索引对应的坐标端点值 $\mathbf{x}_j$ 。结合式 (4-18) 可以证明: 在任意 k 时刻, MPC 问题中系统在 $k+i$ 预测时刻的偏差量 $\mathbf{e}_{k+i|k}$ 以不小于 p 的概率存在于集合 $\mathcal{E}(V, \mathbf{b}(\pi_i, p))$ 中, 即

$$\Pr(\mathbf{e}_{k+i|k}^\top V \mathbf{e}_{k+i|k} \leq \mathbf{b}(\pi_i, p)) \geq p, \forall k \in \mathbb{N}_0 \quad (4-28)$$

式 (4-28) 称为随机管。其本质上是关于 $\mathbf{e}_{k+i|k}$ 不同概率下的椭圆形状置信域

离线部分基于外部扰动 $\mathbf{w}$ 的分布信息得到每个预测时刻偏差量 $\mathbf{e}_{k+i|k}$ 的概率信息。下面将基于该概率信息将 CCOP 转化称确定形式的优化问题并用确定 MPC 框架进行求解。

4.3.2 管随机模型预测控制在线部分

离线得到每一预测时刻偏差量的概率信息 (4-28) 后, 即可在线利用该信息将原问题转化为更易求解的确定性约束优化问题。

首先进行问题形式的转化。为了避免 (4-13) 中难以直接求解的无限维优化问题形式, 此方法使用双模预测范式^[93] 将无限时域问题划分为两部分: **Mode 1** 和 **Mode 2**, **Mode 1** 包括 $i \leq N$ 部分, 此时 (4-16) 中控制变量 $\mathbf{c}_{k+i}$ 是自由变量, **Mode 2** 包括 $i \geq N$ 部分, 此时控制变量 $\mathbf{c}_{k+i} = \mathbf{0}$, 控制器相当于一个纯状态反馈。

然后进行优化问题的转化, 包括期望形式代价函数和机会约束。对于代价函数部分: 由于系统状态受到不确定性影响, (4-13) 中期望和形式的代价函数是无界的, 因此采用修正代价 (4-29) 作为优化问题的代价函数^[94]。

$$J_k = [\mathbf{x}_k^\top \quad \mathbf{c}_k^\top \quad 1] \Omega [\mathbf{x}_k^\top \quad \mathbf{c}_k^\top \quad 1]^\top \quad (4-29)$$

其中 Ω 是适当定义的正定矩阵, 使修改后的代价函数与原代价函数作用相同^[94]。

对于机会约束部分: 将状态分解 (4-14) 代入 (4-13) 中原机会约束, 得到式 (4-30)。由于 $\mathbf{g}^\top \mathbf{e}$ 的分布关于原点对称, (4-30) 可以进一步改写成 (4-31) 的等价形式。最后借助随机管推出的概率条件 (4-33)^[61], 将原机会约束转化成确定约束 (4-34)。

$$\Pr(\mathbf{g}^\top \mathbf{z}_{k+i|k} + \mathbf{g}^\top \mathbf{e}_{k+i|k} \leq h) \geq p \quad (4-30)$$

$$\Pr(\mathbf{g}^\top \mathbf{z}_{k+i|k} + |\mathbf{g}^\top \mathbf{e}_{k+i|k}| \leq h) \geq q = 2p - 1 \quad (4-31)$$

$$\max_{\mathbf{e} \in \mathcal{E}(\mathbf{V}, \mathbf{b})} |\mathbf{g}^\top \mathbf{e}| = b^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}} \quad (4-32)$$

$$\Pr(|\mathbf{g}^\top \mathbf{e}| \leq \mathbf{b}(\pi_i, q)^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}) \geq q \quad (4-33)$$

$$\mathbf{g}^\top \mathbf{z}_{k+i|k} \leq h - \mathbf{b}(\pi_{i|0}, q)^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}} \quad (4-34)$$

进一步, 为了保证递归可行性, 需要将得到的确定性约束 (4-34) 进一步收紧成 (4-35) 的形式, 具体证明见 [61]。递归可行性是指: 当 k 时刻优化问题有可行解 $\mathbf{u}_k$, 则将 $\mathbf{u}_k$ 代入系统后得到 $k+1$ 时刻状态对应的优化问题也有可行解的控制性质。

$$\begin{aligned} \mathbf{g}^\top \mathbf{z}_{k+i|k} &\leq h - [\bar{\mathbf{b}}_i(q)^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}] \\ \bar{\mathbf{b}}_i(q) &= \max\{\mathbf{b}(\pi_{i|0}, q), \dots, \mathbf{b}(\pi_{i|i-1}, q)\} \end{aligned} \quad (4-35)$$

$$\pi_{i|j} = \mathbf{P}^{i-j} \pi_{j|j}, \pi_{j|j} = \mathbf{u}(\text{ind}(\pi_{j|0}, 1))$$

式中 $\mathbf{u}(j)$ ——非零元素均为 1 的下三角矩阵的第 j 列向量, 表示为 $\mathbf{u}(j) = [0, 0, \dots, 1, \dots, 1]$ 。

由于无限时域有无穷多个约束, 我们借助系统的稳定性质, 使用极大容许集理论^[95] 将预测时刻 N 以后的 Mode2 中无穷多个约束转换成有限集合的形式 (4-36), 其中 $\mathbf{b}_\infty^{\frac{1}{2}} = \frac{\bar{\alpha}}{1-\lambda}$, n^* 为转化过程确定的参数。可以证明所得到的优化问题可以保证递归可行性和渐近稳定性^[94]。

$$\begin{aligned} \mathcal{S}_{\hat{N}} &= \left\{ \mathbf{z} \mid \mathbf{g}^\top \Phi^i \mathbf{z} \leq h - \bar{\mathbf{b}}_{N+i}^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}, i = 1, \dots, \hat{N} \right. \\ &\quad \left. \mathbf{g}^\top \Phi^{\hat{N}+j} \mathbf{z} \leq h - \mathbf{b}_\infty^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}, j = 1, \dots, n^* \right\} \end{aligned} \quad (4-36)$$

4.4 基于管的随机模型预测控制的机会约束满足概率偏差分析

从本小节开始到章节末为本章的主要工作和创新部分。在小节 4.3 基于现有的 SMPC 算法分析了其产生机会约束满足概率偏差的原因。并以此为基础在小节 4.4 提出了基于分布函数的 SMPC 算法，最后在小节 4.5 进行了所提算法的性质证明。

在仿真实验中，我们发现 STMPC 算法^[94]的控制效果仍具有较强的保守性，一个明显的表现为：机会约束的实际满足概率远大于预设概率，甚至接近 100%，即和 RMPC 的效果相近。这不符合使用机会约束的目的——通过允许约束可以有一定概率不被满足而非必须被满足以增大可行域，进而增加可行解的数量，减少没有可行解的情况，进而降低控制的保守性。经过分析，我们对该算法导致机会约束实际满足概率与预设概率偏差（后面简称为概率偏差）进而导致控制保守的原因进行了总结，下面进行具体推导和说明。

文献 [94] 在机会约束处理过程中只使用了形如 $\Pr(\mathbf{x} \leq \mathbf{a}) \geq p$ 的概率不等式，即只考虑了各不等式满足的概率下界，而非随机变量实际满足的概率。具体来说，我们首先将机会约束写成它的等价形式 (4-37)，设原机会约束的设定满足概率为 p_{ref} 。

$$\Pr(\mathbf{g}^T \mathbf{z} + |\mathbf{g}^T \mathbf{e}| \leq h) \geq q_{\text{ref}}, \quad q_{\text{ref}} = 2p_{\text{ref}} - 1 \quad (4-37)$$

下面将对 STMPC 算法的推导过程进行回顾，提取并总结导致实际满足概率和预设概率产生偏差的因素。

4.4.1 概率偏差的随机管条件影响因素

在离线部分的随机管概率条件推导过程中可以看到，该算法直接通过 (4-38)，(4-39) 导出 (4-40)。

$$\mathcal{E}(\mathbf{V}, \beta_i) = \{\mathbf{e} \mid \mathbf{e}^T \mathbf{V} \mathbf{e} \leq \beta_i\}, \mathbf{V} = \mathbf{V}^T \succ 0 \quad (4-38)$$

$$\Pr(\beta_i \leq \mathbf{b}(\pi_i, q_{\text{ref}})) \geq q_{\text{ref}} \quad (4-39)$$

$$\Pr(\mathbf{e}^T \mathbf{V} \mathbf{e} \leq \mathbf{b}(\pi_i, q_{\text{ref}})) \geq q_{\text{ref}} \quad (4-40)$$

但实际上只有当 (4-38) 中不等式恒取等时，(4-39) 和 (4-40) 的满足概率才会相同。设式 (4-39)(4-40) 满足的实际概率分别为 q_1, q_2 。在离散误差允许的情况下，我们认为 (4-39) 的随机管概率条件是完全准确的，即 $q_1 = q_{\text{ref}}$ 。

$$\Pr(\beta_i \leq \mathbf{b}(\pi_i, q_{\text{ref}})) = q_1 \quad (4-41)$$

$$\Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \mathbf{b}(\pi, q_{ref})) = q_2 \quad (4-42)$$

则应该有 $q_1 \leq q_2$ ，数学推导如下：

$$\begin{aligned} & \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \mathbf{b}(\pi_i, q_{ref}) \mid \mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \beta_i) = q_2 \\ & = \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \mathbf{b}(\pi_i, q_{ref}) \mid \mathbf{e}^\top \mathbf{V} \mathbf{e} = \beta_i) \cdot \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} = \beta_i) \\ & \quad + \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \mathbf{b}(\pi_i, q_{ref}) \mid \mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \beta_i) \cdot \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \beta_i) \\ & = \Pr(\beta_i \leq \mathbf{b}(\pi_i, q_{ref})) \cdot \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} = \beta_i) \\ & \quad + \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \mathbf{b}(\pi_i, q_{ref}) \mid \mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \beta_i) \cdot \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \beta_i) \\ & \geq \Pr(\beta_i \leq \mathbf{b}(\pi_i, q_{ref})) \cdot \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} = \beta_i) \\ & \quad + \Pr(\beta_i \leq \mathbf{b}(\pi_i, q_{ref})) \cdot \Pr(\mathbf{e}^\top \mathbf{V} \mathbf{e} \leq \beta_i) = q_1 \end{aligned} \quad (4-43)$$

4.4.2 概率偏差的机会约束处理机制因素

对于从机会约束转化为确定约束过程中使用的概率条件：

$$\Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \mathbf{b}(\pi_i, q_{ref})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \geq q_{ref} \quad (4-44)$$

原算法推导中从 (4-42) 直接导出 (4-44)，即认为一个变量属于某个集合的概率不大于将该变量代入一个的函数的值小于此集合内元素代入同一函数的值的最大值的概率。事实上，(4-44) 实际满足的概率可能会比 (4-42) 大很多。设式 (4-44) 实际满足的概率为 q_3 ，即

$$\Pr(|\mathbf{g}^\top \mathbf{e}| \leq \mathbf{b}(\pi_i, q_{ref})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}) = q_3$$

则应该有 $q_2 \leq q_3$ ，数学推导如下：

$$\begin{aligned} & \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \mathbf{b}(\pi_i, q_{ref})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) = q_3 \\ & = \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \mathbf{b}(\pi_i, q_{ref})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}} \mid \mathbf{e} \in \mathcal{E}(\mathbf{V}, \mathbf{b}(\pi_i, q_{ref}))\right) \\ & \quad \times \Pr(\mathbf{e} \in \mathcal{E}(\mathbf{V}, \mathbf{b}(\pi_i, q_{ref}))) \\ & \quad + \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \mathbf{b}(\pi_i, q_{ref})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}} \mid \mathbf{e} \notin \mathcal{E}(\mathbf{V}, \mathbf{b}(\pi_i, q_{ref}))\right) \\ & \quad \times \Pr(\mathbf{e} \notin \mathcal{E}(\mathbf{V}, \mathbf{b}(\pi_i, q_{ref}))) \\ & = 1 \cdot q_2 + \Delta \cdot (1 - q_2) \geq q_2 \end{aligned} \quad (4-45)$$

4.4.3 概率偏差的约束收紧影响因素

为了保证 MPC 问题的递归可行性，将根据随机管的概率性质处理得到的

确定性约束进一步收紧成了更严格的形式 (4-35)

确定性约束和机会约束通过概率条件 (4-44) 相互联系，因此确定性约束变化的时候也代表着概率条件的变化。根据相互关系，当确定性约束收紧到式 (4-35) 的形式，对应的概率条件不再是 (4-44)，而应该是 (4-46) 的形式

$$\Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \bar{\mathbf{b}}_i(q_{\text{ref}})^{1/2} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \geq q_{\text{ref}} \quad (4-46)$$

设式 (4-46) 满足的实际概率为 q_4 ，即

$$\Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \bar{\mathbf{b}}_i(q_{\text{ref}})^{1/2} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) = q_4 \quad (4-47)$$

则应该满足 $q_3 \leq q_4$ ，数学推导如下：

$$\begin{aligned} & \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \bar{\mathbf{b}}_i(q_{\text{ref}})^{1/2} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) = q_4 \\ &= \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \max_{j=0, \dots, i-1} \left\{ \mathbf{b}(\pi_{i|j}, q_{\text{ref}})^{1/2} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}} \right\}\right) \\ &= \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \mathbf{b}(\pi_{i|0}, q_{\text{ref}})^{1/2} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \\ &\quad + \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \max_{j=1, \dots, i-1} \left\{ \mathbf{b}(\pi_{i|j}, q_{\text{ref}})^{1/2} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}} \right\} \mid |\mathbf{g}^\top \mathbf{e}| \geq \mathbf{b}(\pi_{i|0}, q_{\text{ref}})^{1/2} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \\ &\quad \times \Pr\left(|\mathbf{g}^\top \mathbf{e}| \geq \mathbf{b}(\pi_{i|0}, q_{\text{ref}})^{1/2} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \\ &= q_3 + \Delta q_3 \geq q_3 \end{aligned}$$

4.4.4 概率偏差的确定性约束满足因素

原机会约束满足概率等于概率条件满足概率的充要条件是确定约束一直是起作用约束，即把优化问题的解代入约束不等式后左右取等。考虑到这一因素，设确定约束 (4-35) 对应的机会约束满足的概率为 p_5 ，即

$$\begin{aligned} \Pr(\mathbf{g}^\top \mathbf{x} \leq h) &= p_5 \\ \Pr(\mathbf{g}^\top \mathbf{z} + |\mathbf{g}^\top \mathbf{e}| \leq h) &= q_5 = 2p_5 - 1 \end{aligned} \quad (4-49)$$

则有 $q_4 \leq q_5$ ，数学推导如下：

$$\begin{aligned}
 \Pr(\mathbf{g}^\top \mathbf{x} \leq h) &= p_5 \\
 &= \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \bar{\mathbf{b}}_i(q_{\text{ref}})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \\
 &\quad \cdot \Pr\left(\mathbf{g}^\top \mathbf{z} = h - \bar{\mathbf{b}}_i(q_{\text{ref}})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \\
 &\quad + \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq h - \mathbf{g}^\top \mathbf{z} \mid \mathbf{g}^\top \mathbf{z} \leq h - \bar{\mathbf{b}}_i(q_{\text{ref}})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \\
 &\quad \cdot \Pr\left(\mathbf{g}^\top \mathbf{z} \leq h - \bar{\mathbf{b}}_i(q_{\text{ref}})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \\
 &= q_4 + \Delta q_4 \cdot (1 - \Pr(A)) \geq q_4
 \end{aligned} \tag{4-50}$$

式中 Δq_4 ——非负量，满足 $\Delta q_4 \geq 0$ ；

$\Pr(A)$ ——确定性约束在优化问题中作为起作用约束的概率。

显然 $P_A \in [0, 1]$ 。

由此可见，由于文献 [94] 中的推导过程单一地将上述提到的每个不等式的满足概率用同一个概率下界 p_{ref} 表示，而没有考虑每一个不等式的实际满足概率与 p_{ref} 的差距有多大，最终造成机会约束实际满足概率与设定概率偏差的出现进而导致保守的控制结果。

根据上述推导，结合式 (4-43)(4-45)(4-48)(4-50)，我们定义了概率偏差 Δ_{all} 的数学表达式 (4-51)。可以看出， Δ_{all} 与 $\mathbf{e}, \mathbf{e}^\top \mathbf{V} \mathbf{e}$ 的分布函数（这里每个分布函数的维度为预测时域 N ，每一维代表一个预测时刻 i 对应的偏差量相关的分布函数， $i = 1, \dots, N$ ）密切相关。这也是我们后续使用偏差 $\mathbf{e}$ 的分布函数作为概率条件想法的出发点。

$$\begin{aligned}
 \Delta_{\text{all}} &= q_5 - q_{\text{ref}} \\
 &= (q_5 - q_4) + (q_4 - q_3) + (q_3 - q_2) + (q_2 - q_1) \\
 &= (q_1 - q_{\text{ref}}) \\
 &= [1 - \Pr(\text{equal})] \cdot \left[F_{|\mathbf{g}^\top \mathbf{e}|}(h - \mathbf{g}^\top \mathbf{z}) \right. \\
 &\quad \left. - F_{|\mathbf{g}^\top \mathbf{e}|}\left(h - \bar{\mathbf{b}}_i(q_{\text{ref}} - \varepsilon)^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \right] \\
 &\quad + F_{|\mathbf{g}^\top \mathbf{e}|}\left(\max_{j=1, \dots, i-1} \left\{ \mathbf{b}(\pi_{i|j}, q_{\text{ref}})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}} \right\}\right) \\
 &\quad - F_{|\mathbf{g}^\top \mathbf{e}|}\left(\mathbf{b}(\pi_{i|0}, q_{\text{ref}})^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}\right) \\
 &\quad + \Pr\left(|\mathbf{g}^\top \mathbf{e}| \leq \mathbf{b}(\pi_i, q_{\text{ref}} - \varepsilon)^{\frac{1}{2}} \sqrt{\mathbf{g}^\top \mathbf{V}^{-1} \mathbf{g}}, \mathbf{e} \notin \mathcal{E}(\mathbf{V}, \mathbf{b}(\pi_i, q_{\text{ref}}))\right) \\
 &\quad + F_{\mathbf{e}^\top \mathbf{V} \mathbf{e}}(\beta_i) \cdot \left[\frac{F_{\mathbf{e}^\top \mathbf{V} \mathbf{e}}(\mathbf{b}(\pi_i, q_{\text{ref}}) - \varepsilon)}{F_{\mathbf{e}^\top \mathbf{V} \mathbf{e}}(\beta_i)} - F_{\beta_i}(\mathbf{b}(\pi_i, q_{\text{ref}} - \varepsilon)) \right] \geq 0
 \end{aligned} \tag{4-51}$$

可以看出， Δ_{all} ，不仅与每个预测时刻的偏差量分布相关，也与偏差量在不同时间

上的相关性密切相关。这说明在实际控制中，仅依赖单一概率下界 p_{ref} 容易导致保守控制，因此考虑整个偏差量的联合分布可以更精确地满足设计概率。

综上，由于存在概率偏差，STMPC 控制下的概率约束实际满足概率远大于设定概率，控制效果仍具有较大保守性。在下一节中，我们将基于这一分析提出改进的 SMPC 算法，通过利用偏差量的分布函数直接构造概率约束，进一步减小控制保守性，提高系统性能。

4.5 基于分布函数的随机模型预测控制算法理论推导

本节将介绍使用外部扰动 $\mathbf{w}$ 的分布函数计算更准确且合适的概率条件替代随机管概率条件 (4-28)，进而更低保守性地收紧机会约束的方法。该想法基于这样一个事实：式 (4-51) 表明了概率偏差出现的主要原因之一是作为概率条件的随机管的概率性质不准确。因此，如果可以用更准确的与偏差值 $\mathbf{e}$ 相关的概率不等式代替随机管作为新的概率条件处理机会约束，同时证明处理后得到的确定性问题具有需要的控制性质，就可以在保证控制效果的同时，减小概率偏差。（对于代价函数部分，由于文献 [94] 已经证明了其方法从期望形式代价函数转化到确定形式代价函数的等价性，本文仍然继承了这种方法。）为了方便叙述，本节以二维系统和独立同分布的二维正态分布扰动为例进行推导，即 $\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \Sigma)$ 。对于未知分布可以通过高斯过程回归等方法对扰动进行建模。

同样考虑有状态量 $\mathbf{x}_k$ ，输入量 u_k ，扰动量 $\mathbf{w}_k$ 的 LTI 系统：

$$\mathbf{x}_{k+1} = \mathbf{A}\mathbf{x}_k + \mathbf{B}_u u_k + \mathbf{w}_k \quad (4-52)$$

式中 $\mathbf{x}$ ——状态向量，满足 $\mathbf{x} \in \mathbb{R}^{n_x}$ ；

u ——输入向量，满足 $u \in \mathbb{R}^{n_u}$ ；

$\mathbf{w}$ ——扰动向量，满足 $\mathbf{w} \in \mathbb{R}^{n_w}$ ；

$\mathbf{w}_k$ ——零均值的独立同分布随机扰动，其分布函数为 $F_{\mathbf{w}_k}(\mathbf{x})$ 。

随机模型预测控制算法处理的问题是具有机会约束的优化问题 (4-53)，为简便起见这里只考虑单机会约束情况。多约束情况取约束的交集即可。

$$\begin{aligned} \min_{\mathbf{v}_k} J_k &= \sum_{i=0}^{\infty} \mathbb{E}_k (\mathbf{x}_{k+i}^\top \mathbf{Q} \mathbf{x}_{k+i} + u_{k+i}^\top \mathbf{R} u_{k+i}) \\ \text{s.t.} \quad &\Pr(\mathbf{g}^\top \mathbf{x} \leq h) \geq p, \quad p \geq 0.5 \end{aligned} \quad (4-53)$$

我们将系统方程 (4-52) 中的状态 $\mathbf{x}_k$ 分解为标称状态 $\mathbf{z}_k$ 与偏差部分 $\mathbf{e}_k$ 的和，将控制律定义为状态反馈形式，通过将状态分解为标称状态和偏差量，可以将确

定性部分与随机部分分别处理，从而简化机会约束的计算，并为构造随机管提供理论基础。反馈系统 $\mathbf{K}$ 通过 LQR 方法计算。

$$\mathbf{x}_k = \mathbf{z}_k + \mathbf{e}_k \quad (4-54)$$

$$\mathbf{u}_k = \mathbf{K}\mathbf{x}_k + \mathbf{v}_k$$

联立式 (4-52)(4-54) 可以得到：此时 $\mathbf{e}_k$ 和 $\mathbf{z}_k$ 的迭代方程为：

$$\mathbf{z}_{k+1} = \Phi\mathbf{z}_k + \mathbf{B}_u\mathbf{v}_k \quad (4-55)$$

$$\mathbf{e}_{k+1} = \Phi\mathbf{e}_k + \mathbf{B}_w\mathbf{w}_k$$

根据 LQR 的理论， $\Phi = \mathbf{A} + \mathbf{B}_u\mathbf{K}$ 是渐近稳定的。 $\mathbf{v}_{k+i}, i = 0, 1, \dots$ 是时刻 k 下 MPC 问题第 $k+i$ 预测时刻的优化变量。定义 k 时刻下第 $k+i$ 预测时刻的实际状态，标称状态和偏差量分别为 $\mathbf{x}_{k+i|k}, \mathbf{z}_{k+i|k}, \mathbf{e}_{k+i|k}$ 。

类似基于管的随机模型预测控制方法，我们如式 (4-54) 分解系统状态后，可以通过一定的概率条件将原机会约束转换成确定性约束形式 (4-56)。

$$\mathbf{g}^\top \mathbf{z}_j \leq h - h_j \quad (4-56)$$

$$\Pr(\mathbf{g}^\top \mathbf{e}_j \leq h_j) \geq p$$

此时，当处理后的确定性约束是起作用约束（即代入求解得到的优化变量后约束方程左右相等）时，(4-53) 中机会约束的满足概率等于概率条件 (4-56) 的概率。因此，只要用足够准确的与偏差值 $\mathbf{e}$ 相关的概率不等式作为概率条件进行机会约束的处理，同时证明处理得到的确定性问题的递归可行性与渐近稳定性，就可以在保证控制效果的同时，减小概率偏差，降低算法的保守性。

本节以二维系统 ($\mathbf{x}_k \in \mathbb{R}^2$) 和独立同分布的二维正态分布加性扰动 ($\mathbf{w}_k \sim \mathcal{N}(0, \Sigma)$) 为例对基于分布函数的偏差量概率条件进行推导。

首先我们根据已知的扰动信息和系统方程，离线得到获取偏差量概率信息的迭代公式，进而确定基于分布函数的概率条件。

假设在任意 k 时刻的初始状态已知，即 $\mathbf{x}_{k|k} = \mathbf{z}_{k|k}, \mathbf{e}_{k|k} = 0$ 。根据迭代方程 (4-55)，预测时刻 $k+i$ 的偏差量可以表示为：

$$\mathbf{e}_{k+i|k} = \sum_{j=1}^i \Phi^{i-j} \mathbf{B}_w \mathbf{w}_j \quad (4-57)$$

根据式 (4-57) 和正态分布的性质可以写出每一预测时刻 $k+i$ 下偏差量 $\mathbf{e}_{k+i|k}$ 所服从的正态分布。

$$\mathbf{e}_{k+i|k} \sim \mathcal{N}\left(\mathbf{0}, \left(\sum_{j=1}^i \Phi^{i-j} \mathbf{B}_w\right) \Sigma \left(\sum_{j=1}^i \Phi^{i-j} \mathbf{B}_w\right)^\top\right) \quad (4-58)$$

即 $\mathbf{e}_{k+i|k}$ 是均值恒为 0, 方差随 i 的增加不断变大的随机序列。在高斯假设下, 已知参数 $\Phi, \mathbf{B}_w$ 和 $\mathbf{w}$ 的初始方差 Σ 时, $\mathbf{e}_{k+i|k}$ 的分布可以离线确定。将 $\mathbf{e}_{k+i|k}$ 的方差系数记为 $\mathbf{P}_i$, 即有

$$\mathbf{P}_{i+1} = \Phi^\top \mathbf{P}_i \Phi + \mathbf{B}_w^\top \Sigma \mathbf{B}_w, \quad \mathbf{P}_0 = \mathbf{0}, \quad i \geq 0 \quad (4-59)$$

从 (4-58) 可见, 在不同 k 时刻偏差量 $\mathbf{e}_{k+i|k}$ 的分布只和预测步 i 相关而与所处时刻 k 无关, 即对于每一时刻的 MPC 问题, 相同预测步数处偏差量的分布函数都是已知且相同的, 我们简记 $\mathbf{e}_{k+i|k} = \mathbf{e}_i, \forall i = 1, 2, \dots$

知道了偏差量的分布函数, 又由于其本身就是一个准确的概率条件, 且考虑到正态分布良好的性质, 本方法选择使用与偏差值 $\mathbf{e}_i$ 相关的逆累积分布函数 $F_{\mathbf{g}^\top \mathbf{e}_i}^{-1}(\mathbf{x})$ 作为处理机会约束的概率条件。(4-58) 计算出 $\mathbf{e}_i$ 的分布函数后, 根据多维正态分布的性质可以直接得到 $\mathbf{g}^\top \mathbf{e}_i$ 的分布。具体来说, 对于已知条件:

$$\begin{aligned} \mathbf{x}, \mathbf{e} &\in \mathbb{R}^2, \quad \mathbf{u} \in \mathbb{R}^1, \quad \mathbf{g}^\top \in \mathbb{R}^{1 \times 2} \\ \mathbf{g}^\top &= [g_1, g_2], \quad \mathbf{e}_i = \begin{bmatrix} e_{i,1} \\ e_{i,2} \end{bmatrix} \\ \mathbf{P}_i &= \begin{bmatrix} P_{i,(1,1)} & P_{i,(1,2)} \\ P_{i,(2,1)} & P_{i,(2,2)} \end{bmatrix} \end{aligned} \quad (4-60)$$

综合式 (4-59)(4-60) 和二维正态分布随机变量的性质可以得到以下结果:

$$\begin{aligned} \mathbf{g}^\top \mathbf{e}_i &= g_1 e_{i,1} + g_2 e_{i,2} \\ \mathbb{E}(\mathbf{g}^\top \mathbf{e}_i) &= 0 \\ \mathbb{D}(\mathbf{g}^\top \mathbf{e}_i) &= g_1^2 P_{i,(1,1)} + g_2^2 P_{i,(2,2)} + 2g_1 g_2 P_{i,(1,2)} \\ &= \mathbf{g}^\top \left(\sum_{j=1}^i \Phi^{i-j} \right) \Sigma \left[\mathbf{g}^\top \left(\sum_{j=1}^i \Phi^{i-j} \right) \right]^\top \end{aligned} \quad (4-61)$$

式中 $\mathbf{g}$ ——系统参数向量, 满足 $\mathbf{g} \in \mathbb{R}^{n \times 1}$;

n ——系统维数, 本例中取 $n = 2$ 。

从而得到一维正态随机变量 $\mathbf{g}^\top \mathbf{e}_i$ 的分布及其逆概率累积分布函数 $F_{\mathbf{g}^\top \mathbf{e}_i}^{-1}(p)$ 。

$$\begin{aligned} \mathbf{g}^\top \mathbf{e}_i &\sim \mathcal{N}(0, \mathbb{D}(\mathbf{g}^\top \mathbf{e}_i)) \\ F_{\mathbf{g}^\top \mathbf{e}_i}^{-1}(p) &= \sqrt{\mathbb{D}(\mathbf{g}^\top \mathbf{e}_i)} \Phi^{-1}(p) \end{aligned} \quad (4-62)$$

式中 $\Phi^{-1}(p)$ ——标准正态分布的逆累计分布函数；

p ——设定的概率。

我们首先使用 (4-62) 中得到的逆累计分布函数作为概率条件将原机会约束 (4-53) 转化为确定性约束：

$$\begin{aligned} \mathbf{g}^\top \mathbf{z}_{k+i|k} &\leq h - F_{\mathbf{g}^\top \mathbf{e}_i}^{-1}(p_{\text{ref}}) \\ \Pr(\mathbf{g}^\top \mathbf{e}_i &\leq F_{\mathbf{g}^\top \mathbf{e}_i}^{-1}(p_{\text{ref}})) \geq p_{\text{ref}} \end{aligned} \quad (4-63)$$

此时可以保证：当使用 (4-63) 作为约束时，原机会约束以不小于设定概率的概率被满足，但是无法保证转化后的优化问题是否具有递归可行性与渐近稳定性。下面进一步探究能否以及如何进一步将确定约束 (4-63) 处理成可以保证递归可行性与渐近稳定性的形式。

MPC 问题的递归可行性是指 MPC 控制器具有这样的性质：对于 $\forall k \geq 0$ ，当 k 时刻的 MPC 问题具有可行解，则对于任意 $j \in \mathbb{R}^+$ ， $\mathbf{x}_{k+j}$ 时刻的 MPC 问题必有可行解。由于其递归的性质，上面的定义可以等价于对 $\forall k \geq 0$ ，当 k 时刻的 MPC 问题有可行解， $k+1$ 时刻的 MPC 问题也必定有可行解。考虑式 (4-53) 中的问题。类似 [61] 中保证递归可行性的思路，我们需要将确定性约束 (4-63) 进一步收紧，原优化问题 (4-53) 转变为：

$$\begin{aligned} \min_{\mathbf{v}_k} J_k &= \sum_{i=0}^{\infty} \mathbb{E}_k(\mathbf{x}_{k+i}^\top \mathbf{Q} \mathbf{x}_{k+i} + \mathbf{u}_{k+i}^\top \mathbf{R} \mathbf{u}_{k+i}) \\ \text{s.t. } \mathbf{g}^\top \mathbf{z}_{k+j|k} &\leq h - h_j, \quad \forall j = 1, 2, \dots \end{aligned} \quad (4-64)$$

需要保证递归可行性即调整参数 h_j 以保证当 k 时刻有可行解时， $k+1$ 时刻也有可行解。

构造能保证递归可行性的 h_j 的一个直观的出发点是使用移位解的想法^[96]：使 $k+1$ 时刻的一组可行解可以由 k 时刻的一组可行解构造出来，这样即可保证 k 有可行解就一定可以构造出 $k+1$ 时刻的可行解。

我们从无限时域 SMPC 问题出发。假设 k 时刻问题的一组可行解为 $\mathbf{v}_k = [v_{k|k}, v_{k+1|k}, \dots]^\top$ ， $k+1$ 时刻问题的一组可行解为 $\mathbf{v}_{k+1} = [v_{k+1|k+1}, v_{k+2|k+1}, \dots]^\top$ 。下面将探索 h_j 需要满足的形式使得可以由 $\mathbf{v}_k$ 构造 $\mathbf{v}_{k+1}$ 。

首先为了保证原机会约束的概率满足，根据式 (4-63)，(4-65) 应该仍被满足。

$$h_j \geq F_{\mathbf{g}^\top \mathbf{e}_j}^{-1}(p_{\text{ref}}) \quad (4-65)$$

之后取 $\mathbf{v}_{k+i|k+1} = \mathbf{v}_{k+i|k}$, $i = 1, \dots$ 。一方面，将 (4-64) 中 k 时刻问题在 $k+j$ 预测时

刻的约束拆写成由 $\mathbf{z}_{k|k}$ 和 $\mathbf{v}_k$ 组成的多项式的形式 (4-66), $j = 1, \dots$ 。

$$\mathbf{g}^\top \Phi^j \mathbf{z}_{k|k} + \mathbf{g}^\top \sum_{r=1}^j \Phi^{j-r} \mathbf{B}_u \mathbf{v}_{k+r-1|k} \leq h - h_j \quad (4-66)$$

另一方面, 将 $k+1$ 时刻问题在 $k+1+j$ 预测时刻的约束 (4-67)

$$\mathbf{g}^\top \mathbf{z}_{k+1+j|k+1} \leq h - h_j \quad (4-67)$$

同样拆写成由 $\mathbf{z}_{k|k}$ 和 $\mathbf{v}_k$ 组成的多项式的形式 (4-68):

$$\mathbf{g}^\top \Phi^{j+1} \mathbf{z}_{k|k} + \mathbf{g}^\top \sum_{r=1}^j \Phi^{j-r} \mathbf{B}_u \mathbf{v}_{k+r|k+1} + \mathbf{g}^\top \Phi^j (\mathbf{B}_u \mathbf{v}_{k|k} + \mathbf{w}_k) \leq h - h_j \quad (4-68)$$

可以看到: 当取 $\mathbf{v}_{k+i|k+1} = \mathbf{v}_{k+i|k}, i = 1 \dots$ 时, 要使此时 $k+1$ 时刻的约束也满足的一个充分条件是:

$$h_{j+1} \geq h_j + \mathbf{g}^\top \Phi^j \mathbf{w}_k \quad (4-69)$$

综合对原机会约束满足的要求 (4-65), 最终 h_j 需要满足的条件为:

$$h_j \geq \begin{cases} F_{\mathbf{g}^\top \mathbf{e}_1}^{-1}(p_{\text{ref}}) & j = 1 \\ \max \left\{ F_{\mathbf{g}^\top \mathbf{e}_j}^{-1}(p_{\text{ref}}), h_{j-1} + \mathbf{g}^\top \Phi^{j-1} \mathbf{w}_k \right\} & j \geq 2 \end{cases} \quad (4-70)$$

由于扰动 $\mathbf{w}_k$ 是无界随机变量, 因此 h_j 在 $j \geq 2$ 时满足条件的理论取值是无穷大, 这会导致收紧后的约束过于保守以至于没有可行解。因此单纯使用概率条件处理机会约束无法保证无界扰动下的递归可行性。下一小节我们将从受截断的同一扰动条件影响下的系统出发, 分析其递归可行性, 进而推导到无界扰动下递归可行的依概率保证条件。

4.6 基于分布函数的随机模型预测控制算法性质证明

4.6.1 递归可行性的证明

首先对递归可行条件 (4-69) 进行分析: 对于单约束问题来说, $\mathbf{g}^\top \Phi^j \mathbf{w}_k$ 是均值为 0, 方差为 $(\mathbf{g}^\top \Phi^j) \Sigma (\Phi^j)^\top$ 的一维正态分布。同时由于 Σ 是正定矩阵, 因此随机变量 $\mathbf{g}^\top \Phi^j \mathbf{w}_k$ 的标准差可以表示为:

$$\sigma_j = \sqrt{\mathbf{g}^\top \Phi^j \Sigma (\Phi^j)^\top \mathbf{g}} \quad (4-71)$$

下面先考虑对于第 j 个预测时刻下, $\mathbf{g}^\top \Phi^j \mathbf{w}_k$ 在 $3\sigma_j$ 内截断的情况下递归可行性的证明。

引理 4.1 在 $\mathbf{g}^\top \Phi^j \hat{\mathbf{w}}_k \in [-3\sigma_j, 3\sigma_j]$ 的条件下, 如果要保证优化问题 (4-64) 在 k 时刻有可行解时, 其在 $k+1$ 时刻也有可行解, 则需要 h_j 满足:

$$h_j \geq \begin{cases} F_{\mathbf{g}^\top \mathbf{e}_1}^{-1}(p_{\text{ref}}) & j = 1 \\ h_{j-1} + \mathbf{g}^\top \Phi^{j-1} \mathbf{w}_k & j \geq 2 \end{cases} \quad (4-72)$$

证明 我们分为 $j = 1$ 和 $j \geq 2$ 两种部分进行引理 1 的证明。

$j = 1$ 时的证明可以由式 (4-70) 直接确定。

对于 $j \geq 2$ 的部分。在前面中已经说明, 对于任意扰动的实现, 在只用移位解方法证明递归可行性时, h_j 都要满足不等式 (4-70)。式 (4-72) 的形式意味着。对于上述截断后的扰动, 下式恒成立:

$$F_{\mathbf{g}^\top \mathbf{e}_j}^{-1}(p_{\text{ref}}) \leq h_{j-1} + 3\sigma_{j-1}, \quad \forall j \geq 2 \quad (4-73)$$

这里我们通过数学归纳法, 从 $j = 2$ 的情形开始证明 $j \geq 2$ 的情况。

综合式 (4-61) 中 $\mathbf{g}^\top \mathbf{e}_j$ 方差的表达式, 式 (4-71) 中随机变量 $\mathbf{g}^\top \Phi^j \mathbf{w}_k$ 标准差的表达式以及正态分布的逆累计分布函数理论。当 $j = 2$ 时, 式 (4-73) 可以写成:

$$\sqrt{\mathbf{g}^\top (\Phi + I) \Sigma [\mathbf{g}^\top (\Phi + I)]^\top} \Phi^{-1}(p_{\text{ref}}) \leq \sqrt{\mathbf{g}^\top \Sigma (\mathbf{g}^\top)^\top} \Phi^{-1}(p_{\text{ref}}) + 3\sqrt{\mathbf{g}^\top \Phi \Sigma (\mathbf{g}^\top \Phi)^\top} \quad (4-74)$$

由于具有现实意义的机会约束设定概率 p_{ref} 一般都不大于 0.997, 因此可以认为 $\Phi^{-1}(p_{\text{ref}}) \leq \Phi^{-1}(0.997) \leq 3$, 因此我们可以通过证明 (4-74) 的一个充分条件 (4-75) 成立

$$\sqrt{\mathbf{g}^\top (\Phi + I) \Sigma [\mathbf{g}^\top (\Phi + I)]^\top} \leq \sqrt{\mathbf{g}^\top \Sigma (\mathbf{g}^\top)^\top} + \sqrt{\mathbf{g}^\top \Phi \Sigma (\mathbf{g}^\top \Phi)^\top} \quad (4-75)$$

进而证明 (4-74) 成立。由于协方差矩阵 Σ 是正定矩阵, 使用 Cholesky 分解可以将其分解成 $\Sigma = \Sigma_0 \Sigma_0^\top$ 的形式。此时式 (4-75) 可以进一步改写成

$$\sqrt{\mathbf{g}^\top (\Phi + I) \Sigma_0 (\Phi + I)^\top \mathbf{g}} \leq \sqrt{\mathbf{g}^\top \Sigma_0 \mathbf{g}} + \sqrt{\mathbf{g}^\top \Phi \Sigma_0 \Phi^\top \mathbf{g}} \quad (4-76)$$

由于 $\mathbf{g} \in \mathbb{R}^{1 \times 2}$, $\Sigma_0 \in \mathbb{R}^{2 \times 2}$, 我们设 $\mathbf{g}^\top \Sigma_0 = [a_1, b_1]$, $\mathbf{g}^\top \Phi \Sigma_0 = [a_2, b_2]$, 则 $\mathbf{g}^\top (\Phi + I) \Sigma_0 = [a_1 + a_2, b_1 + b_2]$, 式 (4-76) 可以进一步写为

$$\sqrt{(a_1 + a_2)^2 + (b_1 + b_2)^2} \leq \sqrt{a_1^2 + b_1^2} + \sqrt{a_2^2 + b_2^2} \quad (4-77)$$

左右平方化简后有

$$a_1 a_2 + b_1 b_2 \leq \sqrt{(a_1^2 + b_1^2)(a_2^2 + b_2^2)} \quad (4-78)$$

再次左右平方化简得到

$$2a_1a_2b_1b_2 \leq (a_1b_2)^2 + (a_2b_1)^2 \quad (4-79)$$

即

$$(a_1b_2 - a_2b_1)^2 \geq 0 \quad (4-80)$$

这个结果显然成立，进而证明了条件 (4-75) 成立。

至此，我们通过证明充分条件 (4-75) 的成立证明了 $j = 2$ 时式 (4-73) 成立。

对 $j \geq 2$ 的情况，我们设 $j \leq r, r \geq 1$ 时式 (4-73) 都成立，下面证 $j = r + 1$ 时式 (4-73) 仍成立：

由于 $j = r$ 时式 (4-73) 成立，因此有 $h_r \geq F_{g^\top e_r}^{-1}$ 。我们将

$$g^\top \left(\sum_{m=1}^{r+1} \Phi^{r+1-m} \right) \Sigma_0 \quad (4-81)$$

分解为

$$g^\top \left(\sum_{m=1}^r \Phi^{r-m} \right) \Sigma_0 + g^\top \Phi^r \Sigma_0 \quad (4-82)$$

类比 $j = 2$ 的证明过程 (4-74) 到 (4-77)，可以推出

$$\begin{aligned} & \sqrt{g^\top \left(\sum_{m=1}^{r+1} \Phi^{r+1-m} \right) \Sigma \left[g^\top \left(\sum_{m=1}^{r+1} \Phi^{r+1-m} \right) \right]^\top} \\ & \leq \sqrt{g^\top \left(\sum_{m=1}^r \Phi^{r-m} \right) \Sigma \left[g^\top \left(\sum_{m=1}^r \Phi^{r-m} \right) \right]^\top} + \sqrt{g^\top \Phi^r \Sigma (g^\top \Phi^r)^\top} \end{aligned} \quad (4-83)$$

即 $F_{g^\top e_{r+1}}^{-1}(p_{\text{ref}}) \leq F_{g^\top e_r}^{-1} + 3\sigma_r \leq h_r + 3\sigma_r$ ，即 $j = r + 1$ 时，式 (4-73) 仍成立。□

至此，我们证明了在 3σ 截断正态分布的扰动下，对于无限时域 SMPC 问题，在进行如式 (4-56) 的约束收紧时，如果能保证对于任意 $j \geq 1$ ，约束收紧参数 h_j 恒满足式 (4-72) 的条件，那么通过 h_j 进行约束收紧后得到的确定 MPC 问题具有递归可行性。将 (4-72) 写成非迭代形式为：

$$h_j \geq F_{g^\top e_1}^{-1}(p_{\text{ref}}) + 3 \sum_{r=1}^{j-1} \sigma_r \quad (4-84)$$

由于无限时域问题会导致预测模型维度为无限维，无法直接实现且难以求解，因此一般确定性 MPC 都从无限时域问题转化为有限时域问题问题后进行求解^[59]。下面基于确定性 MPC 问题从无限时域到优化问题的转化过程和转化条件，对收紧约束后得到的确定性 MPC 问题进行从无限时域到有限时域的转化。

首先通过引理4.2证明了通过 h_j 收紧后得到的优化问题具有将无限时域问题转化为有限时域加终端约束形式问题需要的极大可容许集性质。

引理 4.2 式 (4-84) 中 h_j 的下界是单调有界序列。

证明 由于 $\sigma_r \geq 0, \forall r \geq 0$, 单调性很容易看出。对于有界性, 我们让 $j \rightarrow \infty$ 来求得极限值。

首先将 (4-55) 中系统矩阵进行特征值分解: $\Phi = T\Lambda T^{-1}$, 综合前面对 Σ 的 Cholesky 分解 $\Sigma = \Sigma_0 \Sigma_0^T$, 我们可以结合式 (4-71)(4-84) 将关于收紧后约束的表达式右侧的 $g^T \Phi^i \Sigma (g^T \Phi^i)^T$ 写作以下形式:

$$g^T \Phi^i \Sigma (g^T \Phi^i)^T = g^T T \Lambda^i T^{-1} \Sigma_0 (T^{-1})^T \Lambda^i T^T g \quad (4-85)$$

设 $\Lambda = \begin{bmatrix} a & 0 \\ 0 & b \end{bmatrix}$ 。 (4-85) 中除了预测时刻 i 外其余参数固定, 因此可以将式 (4-85) 简写为矩阵内积形式:

$$g^T \Phi^i \Sigma (g^T \Phi^i)^T = \begin{bmatrix} Ma^i & Nb^i \end{bmatrix} \begin{bmatrix} Ma^i & Nb^i \end{bmatrix}^T \quad (4-86)$$

式中 M ——推导过程中整理得到的标量;

N ——推导过程中整理得到的标量。

此时我们可以将 h_j 需要满足的条件表达式 (4-84) 进一步写成:

$$\begin{aligned} h_j &\geq F_{g^T e_1}^{-1}(p_{\text{ref}}) + 3 \sum_{r=1}^{j-1} \sqrt{\begin{bmatrix} Ma^r & Nb^r \end{bmatrix} \begin{bmatrix} Ma^r & Nb^r \end{bmatrix}^T} \\ &= F_{g^T e_1}^{-1}(p_{\text{ref}}) + 3 \sum_{r=1}^{j-1} |Ma^r + Nb^r| \end{aligned} \quad (4-87)$$

容易看出式 (4-87) 有上界且上界为:

$$F_{g^T e_1}^{-1}(p_{\text{ref}}) + 3 \sum_{r=1}^{j-1} |Ma^r + Nb^r| \leq F_{g^T e_1}^{-1}(p_{\text{ref}}) + 3 \left(\frac{M}{1-|a|} + \frac{N}{1-|b|} \right) \quad (4-88) \quad \square$$

由于 Φ 是稳定系统, h_j 单调有上界, 此时约束收紧后得到的 MPC 问题 (4-64) 满足极大可容许集理论的要求, 可以将无限时域问题转换成有限时域加终端约束的形式^[95]。综合极大可容许集理论^[95], 双模预测范式理论^[93] 以及式 (4-84)。转化后的有限时域约束可以写作以下形式:

$$\begin{aligned}
 & \mathbf{g}^\top \mathbf{z}_{k+j|k} \leq h - h_j, \quad j = 1, \dots, N \\
 & \mathbf{z}_{N|k} \in \mathcal{S}_{\hat{N}} \\
 & \mathcal{S}_{\hat{N}} = \left\{ \mathbf{z}_{N|k} : \mathbf{g}^\top \Phi^r \mathbf{z}_{N|k} \leq h - h_{N+r}, \quad r = 1, \dots, \hat{N} \right. \\
 & \quad \left. \mathbf{g}^\top \Phi^{\hat{N}+j} \mathbf{z}_{N|k} \leq h - h_\infty, \quad j = 0, \dots, n^* \right\}
 \end{aligned} \tag{4-89}$$

$\hat{N}, n^*$ 为转化过程中确定的整数参数。同时代价函数也可以写成以下有限时域的形式^[61]:

$$J_k = \sum_{i=0}^{\infty} (\mathbb{E}_k(L_{k+i}) - L_{ss}), \quad L_{ss} = \lim_{i \rightarrow \infty} \mathbb{E}_k(L_{k+i}) \tag{4-90}$$

其中 $L_{k+i} = \mathbf{x}_{k+i}^\top \mathbf{Q} \mathbf{x}_{k+i} + \mathbf{u}_{k+i}^\top \mathbf{R} \mathbf{u}_{k+i}$ 。其可以写成 k 时刻自由变量向量 $\mathbf{v}_{k+i}, i = 0, \dots, N-1$ 的二次函数^[94], Ω 为适当定义的正定矩阵^[94]

$$J_k = \left[\mathbf{x}_k^\top \quad \mathbf{c}_k^\top \quad 1 \right] \Omega \left[\mathbf{x}_k^\top \quad \mathbf{c}_k^\top \quad 1 \right]^\top \tag{4-91}$$

改写后的问题和原无限时域截断扰动问题等价, 因此 (4-89) 作为约束的优化问题在截断扰动条件下仍然具有递归可行性。

上面我们构造了截断扰动条件下可保证递归可行的优化问题, 下面探究式 (4-90) 与式 (4-89) 所构造的问题形式在无界扰动条件下是否仍然具有递归可行性或者与其相关的性质。

定理 4.1 对于在截断条件 $\mathbf{g}^\top \Phi^j \hat{\mathbf{w}}_k \in [-3\sigma_j, 3\sigma_j]$ 下构造的具有递归可行的优化问题约束条件 (4-89), 通过将其终端约束收紧成概率不变集, 可以保证其在非截断扰动条件下可以依一定概率递归可行, 即对 $\forall k \geq 0$, 当 k 时刻优化问题有可行解, 则存在一个概率下界 P , 使 $k+1$ 时刻的优化问题有可行解的概率不小于 P 。

证明 我们将无界扰动下递归可行的概率其用以下条件概率表示:

$$\begin{aligned}
 & P(\text{无界扰动递归可行} \mid \text{截断扰动递归可行}) \\
 & = P \left(h_j \geq F_{\mathbf{g}^\top \mathbf{e}_1}^{-1} + \sum_{r=1}^{j-1} \mathbf{g}^\top \Phi^r \mathbf{w}_k \mid h_j \geq F_{\mathbf{g}^\top \mathbf{e}_1}^{-1} + 3 \sum_{r=1}^{j-1} \sigma_r \right) \\
 & \quad \cdot P((\Phi \mathbf{z}_{k+N|k} + \Phi^N \mathbf{w}_k) \in \mathcal{S}_{\hat{N}} \mid \mathbf{z}_{k+N|k} \in \mathcal{S}_{\hat{N}}) \\
 & = P_1 \cdot P_2, \quad \forall j = 1, \dots, N-1
 \end{aligned}$$

式中 P_1 ——条件概率, 表示 h_j 在给定不等式条件下的发生概率;

P_2 ——条件概率, 表示经过系统动力学演化后状态落在集合 $\mathcal{S}_{\hat{N}}$ 的概率。

下面将对 P_1 和 P_2 分别进行分析:

对于 P_1 : 在已知 $h_j \geq F_{\mathbf{g}^\top \mathbf{e}_1}^{-1} + 3 \sum_{r=1}^{j-1} \sigma_r, \forall j = 1, \dots, N-1$ 时, 满足 $h_j \geq F_{\mathbf{g}^\top \mathbf{e}_1}^{-1} + \sum_{r=1}^{j-1} \mathbf{g}^\top \Phi^r \mathbf{w}_k, \forall j = 1, \dots, N-1$ 的一个充分条件是 $\mathbf{g}^\top \Phi^j \mathbf{w} \leq 3\sigma_j, \forall j = 1, \dots, N-1$, 因此可以找到一个 P_1 的下界:

$$P_1 \geq P'_1 = P(\mathbf{g}^\top \Phi^r \mathbf{w}_k \leq 3\sigma_r, \forall r = 1, \dots, N-1) \quad (4-92)$$

记 $\mathbf{A} = [\mathbf{g}^\top \Phi, \dots, \mathbf{g}^\top \Phi^{N-1}]^\top$, $\mathbf{b} = [3\sigma_1, \dots, 3\sigma_{N-1}]^\top$ 。则可以将式 (4-92) 改写成

$$P_1 \geq P'_1 = P(\mathbf{A}\mathbf{w}_k \leq \mathbf{b}) \quad (4-93)$$

由正态分布的性质和 $\mathbf{w}$ 的分布信息, 可以推出 $\mathbf{A}\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \mathbf{A}\Sigma\mathbf{A}^\top)$, 其概率密度函数为

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^k \det(\mathbf{A}\Sigma\mathbf{A}^\top)}} \exp\left(-\frac{1}{2}\mathbf{x}^\top (\mathbf{A}\Sigma\mathbf{A}^\top)^{-1} \mathbf{x}\right)$$

因此 $P'_1 = \iint_{\mathbf{A}\mathbf{x} \leq \mathbf{b}} f(\mathbf{x}) d\mathbf{x}_1 \dots d\mathbf{x}_{N-1}$, 其中 $\mathbf{x}_i$ 表示向量 $\mathbf{x}$ 的第 i 个元素。

对于 P_2 : 根据文献 [95], $\mathcal{S}_{\hat{N}}$ 是第 N 步标称预测状态 $\mathbf{x}_{k+N|k}$ 的正不变集, 即满足 $P(\Phi \mathbf{z}_{k+N|k} \in \mathcal{S}_{\hat{N}} \mid \mathbf{z}_{k+N|k} \in \mathcal{S}_{\hat{N}}) = 1$, 而无法直接计算 P_2 的相关概率。为了解决这个问题, 我们采用概率正不变集 (Probabilistic Invariant Sets, PIS)^[97] 理论。概率正不变集是正不变集的延伸, 指一类具有这样性质的集合: 当 k 时刻的状态处于概率参数为 p 的概率正不变集内, 则对 $\forall j \geq 0, k+j$ 时刻的状态以下界为 p 的概率仍处于这个概率正不变集中。这刚好满足 P_2 条件概率的形式。因此要计算 P_2 的值, 只需要通过将正不变集收紧成概率正不变集形式即可。具体来说: 我们定义以下渐近稳定的辅助系统:

$$\begin{aligned} \mathbf{x}_{k+1} &= \mathbf{A}_{sup} \mathbf{x}_k + \mathbf{m}_k \\ \mathbf{x}_k &\in \mathcal{X}_{sup} \\ \mathbf{m}_k &\sim \mathcal{Q}^m = \mathcal{N}(\mathbf{0}, \Sigma_m) \end{aligned} \quad (4-94)$$

系统方程和 P_2 左边结构一样。对于无界的扰动 $\mathbf{m}_k \in \mathbb{R}^n, \mathbb{E}(\mathbf{m}) = \mathbf{0}, \text{Var}(\mathbf{m}) = \Sigma_m$ 。基于 PIS 理论, 当取随机变量 $\mathbf{m}_k$ 的盒状置信域 $\mathbb{E}_p^b(\mathcal{Q}^m) = \left\{ \overline{\mathbf{m}} \mid [\overline{\mathbf{m}}]_i^2 \leq \frac{[\Sigma_m]_{ii}}{\tilde{p}_i}, i = 1, \dots, n \right\}$, $p = 1 - \sum_{i=1}^n \tilde{p}_i$ 。其中 $P(\mathbf{m}_k \in \mathcal{E}_p^b(\mathcal{Q}^m)) = p$ 时, 使用 $\mathbf{x}_k \in \mathcal{X}, \mathbf{m}_k \in \mathcal{E}_p^b(\mathcal{Q}^m)$ 计算得到的鲁棒正不变集 $\mathcal{X}_p^R = \{\mathbf{x}_k \in \mathcal{X}, \mathbf{m}_k \in \mathcal{Q}^m\}$ 的概率为 p 的概率正不变集^[97]。(鲁棒正不变集具体计算过程见文献 [98])。我们将辅助系统 (4-94) 中 $\mathbf{x}_k, \mathbf{A}_{sup}, \mathbf{m}_k, \mathcal{X}_{sup}$ 替换为 $\mathbf{z}_{k+N|k}, \Phi, \Phi^N \mathbf{w}_k, \mathcal{S}_N$ 。可以得到

$P_2 \geq p$ 。 □

至此我们确定了可以依概率保证递归可行的最终的确定性约束为：

$$\begin{aligned} g^\top z_{k+j|k} &\leq h - h_j, j = 1, \dots, N \\ z_{N|k} &\in S_{\hat{N}}^R \end{aligned} \quad (4-95)$$

k 时刻有可行解保证 $k+1$ 时刻有可行解的概率为 $P = P_1 P_2 \geq P'_1 p$ ：

注释 4.1 一般式 (4-93) 中多面体非空且概率正不变集 $\mathcal{X}_p^R$ 非空。因此可以认为 $P_1, P_2 \neq 0$ 。此外，本文证明的递归可行实际上是一种依概率递归可行，即从 k 时刻可行推导出 $k+1$ 时刻可行，当预测时域无限大时，这个概率会趋近于 0。这个结果符合现实逻辑，即在无界扰动下，无论如何都无法保证完全稳定，且时间线拉的越长这个不稳定情况出现的几率越大。

4.6.2 渐近稳定性的证明

定理 4.2 考虑到对于 $\forall k \geq 0$ 确保可行性，优化问题 (4-89) 在时刻 $k+1$ 以至少概率 p 是可行的。因此，闭环系统可以至少以概率 p 满足机会约束 (4-53) 并满足二次稳定性标准。

$$\lim_{n \rightarrow \infty} \frac{1}{n} \sum_{k=0}^n \mathbb{E}_0(L_k) \leq L_{ss} \quad (4-96)$$

证明 递归可行性遵循定理 4.1，这意味着基于在 k 时刻优化问题的最优解序列 $\mathbf{v}_k^* = \{\mathbf{v}_k, \dots, \mathbf{v}_{k+N-1}\}$ 构建的新序列 $\mathbf{v}_{k+1|k} = \{\mathbf{v}_{k+1}, \dots, \mathbf{v}_{k+N-1}, 0\}$ 对于时刻 $k+1$ 的优化问题约束 (4-89) 是依至少 p 的概率可行的。这种概率可行性意味着最优成本满足 $J_k^* - \mathbb{E}_k(J_{k+1}^*) \geq L_k - L_{ss}$ ，这保证了 (4-96) 的成立。 □

4.6.3 低保守分析的说明

由于所提出算法的出发点是减少机会约束实际满足概率和预设概率的偏差，即降低算法保守性，本小节对所提出算法的保守性进行了定量分析。我们定义机会约束实际满足的概率 p 与优化问题中机会约束的设定概率 p_{ref} 之间的差值为 Δ_{all} 来量化表示这种保守性。具体而言，这个差值的绝对值越小，说明机会约束的作用越明显，算法的保守性就越低（当机会约束百分百被满足时，控制效果等价于鲁棒控制，保守性较大）。参考 STMPC 中的保守性分析过程 (4-43)(4-45)(4-48)(4-50)，由于使用了分布函数直接作为概率条件进行机会约束的处理，因此概率条件本身并没有固有偏差。此时可以确定概率的偏差来源于两个因素：收紧约束以确保递归可行性的过程，以及收紧后约束作为有效约束

(代入最优解后约束左右两边的值是否相等)的具体情况。

下面将上述两个因素对保守性的影响进行量化表示：当只考虑将机会约束转化等效为确定性约束而不考虑递归可行性时，修改后的约束以一定概率满足原始机会约束，并且这个满足原机会约束的概率与转化过程中使用的概率条件直接相关。具体而言，通过机会约束处理，原始机会约束被转化为方程 (4-97) 的形式。

$$\begin{aligned} \mathbf{g}^\top \mathbf{z}_{k+j|k} &\leq h - F_{\mathbf{g}^\top \mathbf{e}_j}^{-1}(p_{\text{ref}}) \\ \Pr(\mathbf{g}^\top \mathbf{e}_j &\leq F_{\mathbf{g}^\top \mathbf{e}_j}^{-1}(p_{\text{ref}})) \geq p_1 \end{aligned} \quad (4-97)$$

根据逆累积分布函数的定义， $p_1 = p_{\text{ref}}$ 。而为了进一步确保递归可行性，我们提出的算法所使用的实际的概率条件应该表示为 (4-98)。

$$\Pr(\mathbf{g}^\top \mathbf{e}_j \leq h_j) \geq p_2 \quad (4-98)$$

根据式 (4-84)，我们有：

$$p_2 = \begin{cases} p_1, & j = 1 \\ F_{\mathbf{g}^\top \mathbf{e}_j} \left(F_{\mathbf{g}^\top \mathbf{e}_1}^{-1}(p_{\text{ref}}) + 3 \sum_{r=1}^{j-1} \sigma_r \right), & j \geq 2 \end{cases} \quad (4-99)$$

其中 j 为预测时刻。在评估收紧约束是否是有效约束所产生的影响时，可以通过比较实际约束满足水平与约束边界量化这部分保守性。具体来说，如果处理后的不等式约束不是有效约束，则存在一个满足方程 (4-101) 的参数 η ($\eta \geq 0$)。在这种情况下，相应的概率条件为：

$$\Pr(\mathbf{g}^\top \mathbf{e}_j \leq h_j + \eta_j) \geq p_3 \quad (4-100)$$

$$\mathbf{g}^\top \mathbf{z}_{k+j|k} + \eta_j = h - h_j \quad (4-101)$$

p_3 表示满足机会约束的实际概率。通过结合方程 (4-98)、(4-99) 和 (4-100) 可以发现，如果将当前输入值应用于真实系统，则满足机会约束的实际概率为：

$$p_3 = \begin{cases} F_{\mathbf{g}^\top \mathbf{e}_j} \left(F_{\mathbf{g}^\top \mathbf{e}_j}^{-1}(p_{\text{ref}}) + \eta_j \right) & j = 1 \\ F_{\mathbf{g}^\top \mathbf{e}_j} \left(F_{\mathbf{g}^\top \mathbf{e}_j}^{-1}(p_{\text{ref}}) + 3\sigma_{\mathbf{g}^\top \mathbf{e}_j} + \sigma_{\mathbf{g}^\top \mathbf{e}_1} + \eta_j \right) & j \geq 2 \end{cases} \quad (4-102)$$

由于滚动优化，只有第一个输入实际应用于系统。因此，理论概率值与设定值之间的偏差 Δ_{all} 仅与对应于 $j = 1$ 的 p_1, p_2 和 p_3 相关，如下所示：

$$\begin{aligned} \Delta_{\text{all}} &= p_3 - p_1 = (p_3 - p_2) + (p_2 - p_1) \\ &= F_{\mathbf{g}^\top \mathbf{e}_1} \left(F_{\mathbf{g}^\top \mathbf{e}_1}^{-1}(p_{\text{ref}}) + \eta_j \right) - p_{\text{ref}} \end{aligned} \quad (4-103)$$

也就是说，当所有处理后的约束作为有效约束时，该方法的理想概率偏差接近 0，这在理论上展示了此算法的低保守性。

4.7 实验结果

前面已经证明，与 Tube-Based RMPC 和 STMPC 相比，所提出的随机模型预测控制（SMPC）算法在约束收紧后能够提供更大的可行区域，从而表现出更低的保守性。可行区域的扩大表明系统保守性的降低，因为这意味着优化问题具有可行解的可能性增大。

为了进一步验证该结论，我们考虑以下具有单一约束的二阶系统优化问题，并在 MATLAB 环境下进行数值实验。实验在配备 Intel(R) Core(TM) i7-8700 CPU @ 3.20 GHz 的计算机上完成。通过在不同约束处理后的对比分析，可以直观地观察到所提算法在保持系统稳定性和约束可行性方面的优势。

$$\begin{aligned} A &= \begin{bmatrix} 1.8 & -0.5 \\ -1.5 & 1.2 \end{bmatrix} & B_u &= \begin{bmatrix} 2 \\ 1 \end{bmatrix} & w_k &\sim \mathcal{N}(\mathbf{0}, \Sigma) \\ \Sigma &= \begin{bmatrix} 0.02 & 0 \\ 0 & 0.04 \end{bmatrix} & \Pr(g^\top x_k \leq h) &\geq p & p &= 0.8 \\ g &= \begin{bmatrix} -1.75 \\ 1 \end{bmatrix} & h &= 1.1 & Q &= \begin{bmatrix} 5 & 0 \\ 0 & 5 \end{bmatrix} & R &= 1 \quad N = 6 \\ x_0 = z_0 &= \begin{bmatrix} 0.2 \\ 0.4 \end{bmatrix} & e_0 &= \begin{bmatrix} 0 \\ 0 \end{bmatrix} & v &\in V = \{-0.5 \leq v \leq 0.5\} \end{aligned}$$

在具体仿真实验中，我们的随机模型预测控制算法处理无界高斯不确定性，对应于图 4-1 中的“OURS”区域。而由于基于管道的鲁棒模型预测控制（Tube Based RMPC）和 STMPC 只能处理有界扰动，因此作为对比算法需要在无界高斯不确定性的基础上添加额外条件。具体而言：Tube Based RMPC 算法通过无界高斯不确定性之上施加以下额外限制条件来处理不确定性。

$$w_k^{(r)} \in \mathcal{E}_p^b(Q^w) = \left\{ w \mid [w]_i^2 \leq \frac{[\Sigma]_{ii}}{\tilde{p}_i}, i = 1, 2 \right\}$$

式中 $w_k^{(r)}$ ——表示 RMPC 中的有界扰动变量；

p ——计算公式为 $p = 1 - \sum_{i=1}^2 \tilde{p}_i$ 。

在这个示例中，我们设定 $p = 0.8$ ，且 $\tilde{p}_1 = \tilde{p}_2 = \frac{1-p}{2}$ 。显然， $\mathcal{E}_p^b(Q^w)$ 是无界高斯不确定性的一个子集。 $\mathcal{E}_p^b(Q^w)$ 对应于图 4-1 中的“tube based RMPC”区域。

在 STMPC 中，我们同样对不确定性添加了以下额外限制条件：

$$-2.68 \leq (\mathbf{w}_k^{(s)})_{1,2} \leq 2.68$$

$$\mathbf{w}_k^{(s)} \in \mathcal{E}(\mathbf{W}, \alpha_k) = \{\mathbf{w} \mid \mathbf{w}^\top \mathbf{W} \mathbf{w} \leq \alpha_k\} \quad \mathbf{W} = \mathbf{I}$$

式中 $\mathbf{w}_k^{(s)}$ ——STMPC 中的扰动变量；

α_k ——服从具有三个自由度的截断卡方分布，取值范围为 $[0, 0.1]$ ；

$\mathcal{E}(\mathbf{W}, \alpha_k)$ ——无界高斯不确定性的子集，对应于图 4-1 中的“STMPC”区域。

上述配置的设置目的在于，使本文所提出算法在实验中所面对的扰动范围明显大于对比算法，同时保证各算法所对应的不确定性分布形状保持一致。通过这种方式，可以避免由于扰动分布差异而对实验结果造成的干扰，从而使不同方法之间的对比更加公平。

在这样的实验条件下，对比算法实际上是在更为“宽松”的环境中运行，即其受到的扰动幅度更小、系统不确定性更低。如果在这种情况下，本文方法仍然能够在满足安全约束的前提下，获得比对比算法更大的可行区域，表现出更低的保守性，则可以认为该优势并非源于实验条件的有利设置，而是算法本身在处理不确定性和机会约束方面具有更强的能力。

因此，上述实验配置为算法保守性比较提供了一个相对严格的评估标准，在此基础上得到的结果能够更加充分地说明本文方法在降低保守性方面的有效性。

图 4-1 展示了三种外部扰动的分布信息。我们使用 MATLAB 进行模拟实验，并通过多参数工具箱 (Multi-Parametric Toolbox, MPT)^[78] 处理约束。在对比实验中，我们主要关注可行区域的相对大小。我们将 Tube Based RMPC、STMPC 和我们的算法的可行区域分别定义为 $\mathcal{S}^{\text{RMPC}}$, $\mathcal{S}^{\text{STMPC}}$ 和 $\mathcal{S}^{\text{OURS}}$ ，并将对应算法下第 i 步预测时刻的约束定义为 $\mathcal{Z}_i^{\text{RMPC}}$, $\mathcal{Z}_i^{\text{STMPC}}$ 和 $\mathcal{Z}_i^{\text{OURS}}$ 。由于这些算法已经保证了递归可行或依概率递归可行，我们有：

$$\begin{aligned} \mathcal{S}^{\text{Alg}} &= \{\mathbf{z}_0 \mid \mathbf{z}_{0+i} \in \mathcal{Z}_i^{\text{Alg}}, \mathbf{z}_i = \Phi \mathbf{z}_{i-1} + \mathbf{B} \mathbf{v}_{i-1} \\ &\quad \exists \mathbf{v}_i \in \mathcal{V}, i = 1, \dots, N, \text{Alg} = \text{RMPC}, \text{STMPC}, \text{OURS}\} \end{aligned} \quad (4-104)$$

从方程 (4-55) 可以推导出每个预测步骤中名义状态 $\mathbf{z}$ 的表达式如下：

$$\mathbf{z}_{0+i} = \Phi^i \mathbf{z}_0 + \sum_{k=0}^{i-1} \Phi^{i-1-k} \mathbf{B} \mathbf{v}_k$$




图 4-1 RMPC, STMPC 和本文中的算法处理的不确定性概率密度图

每个算法在每个预测步骤 i 的约束可以表示为以下形式:

$$\Phi^{i-1}z_0 + \sum_{k=0}^{i-1} \Phi^{i-1-k} B v_k \in Z_i^j, \quad \exists v_i \in V$$

其中 Alg 与方程 (4-104) 中的定义相同。现在方程 (4-104) 可以重写为交集的形式:

$$S^{\text{Alg}} = \left\{ z_0 \left| z_0 \in \bigcap_{i=0}^{N-1} \Phi^{-(i-1)} \left(z_i - \sum_{k=0}^{i-1} \Phi^{i-1-k} B v_k \right) \right. \right. \\ \left. \left. z_i \in Z_i^{\text{Alg}}, v_k \in V, \text{Alg} = \text{RMPC}, \text{STMPC}, \text{OURS} \right\}$$

可以观察到, 对于所有三种不同的算法, 如果存在一个算法 ALG, 使得 $Z_i^{\text{ALG}} \supset Z_i^{\text{alg}} \forall i = 1, \dots, N$, 其中 alg_i 代表除 Alg 之外的其他任一算法, 那么 $S^{\text{ALG}} \supset S^{\text{alg}}$, 即算法 ALG 有最大的可行区域, 则可以认为其在待比较算法中具有最低的保守性。由于实验例子为线性单约束问题, 约束形式可以写成 $Ax \leq b$ 的形式。基于本文推导及文献 [61],[99] 可知, 实验中所涉及算法的约束收紧本质上都是对 b 进行处理, 即 A 是相同的, 因此可以通过比较收紧后约束的参数 b 的大小对可行区域的大小进行比较。表4-2为每一预测时域下可行区域的数学表达式 A 、 b 的大小。可以看出在每个预测时刻, 我们的方法都具有最大的可行区域。图4-2, 4-3展示了三种不同算法在第一个预测时刻下的可行区域。

表 4-2 不同预测时刻下算法可行域参数

预测时刻	RMPC:A	RMPC:b	STMPC:A	STMPC:b	OURS:A	OURS:b
1	[-1.75,1]	0.5780	[-1.75,1]	0.6836	[-1.75,1]	1.0194
2	[-1.75,1]	0.5780	[-1.75,1]	0.5315	[-1.75,1]	0.7888
3	[-1.75,1]	0.5780	[-1.75,1]	0.4977	[-1.75,1]	0.7173
4	[-1.75,1]	0.5780	[-1.75,1]	0.4915	[-1.75,1]	0.6945
5	[-1.75,1]	0.5780	[-1.75,1]	0.4895	[-1.75,1]	0.6873
6	[-1.75,1]	0.5780	[-1.75,1]	0.4895	[-1.75,1]	0.6850




图 4-2 各算法可行域




图 4-3 各算法可行域对比图

4.8 本章小结

在本章中，我们首先在小节 4.1 介绍了基本的 MPC 框架，提出其鲁棒效果不足的问题，并在小节末引出对一种特殊形式的 MPC：SMPC 研究的必要性。之后在小节 4.2 介绍了基于管的 SMPC 的基本原理。在前两节先验知识的基础上，从小节 4.3 开始到小节 4.5 从量化传统的 STMPC 算法的缺点出发推导构建出了一种新的 SMPC 算法，同时在理论上证明了其包括递归可行性和渐近稳定性在内的控制性质，以及在理论上的低保守性。在仿真实验部分，我们将提出的算法应用到二阶系统的优化问题中，并与传统的 Tube Based RMPC 算法和 STMPC 算法进行对比，理论分析与实验结果表明，本文提出的算法不仅能够有效求解机会约束优化问题，而且在一定条件下具备相应的理论性质保证。同时，与对比算法相比，该方法在满足安全约束的前提下表现出了更低的保守性

结 论

安全控制与抗扰动控制是推动控制算法实际应用的关键研究方向。实际系统运行必须保障安全性，同时面临不确定性及扰动的挑战，如环境变化、传感器噪声等，这些因素会引发系统失稳或安全风险。因此，确定系统的安全范围以及在不确定条件下确保系统安全与稳定至关重要。本文围绕控制障碍函数、强化学习与模型预测控制，提出了若干创新性解决方案，并验证了其有效性。

在控制障碍函数方面，本文提出了一种基于分片仿射神经网络（PWANN）的控制障碍函数逼近方法。利用 PWANN 的局部线性性质将训练中优化问题的求解次数从采样点数次降低至分片常数次，显著提升了训练效率。同时，采用优化问题替代固定控制律的训练思路，扩展了可行安全集的范围。实验表明该方法在高维复杂系统中能够有效逼近控制障碍函数，并在训练时间上展现优势。

在强化学习方面，本文对现有机会约束强化学习框架进行了改进。改进后的方法使机会约束满足概率更精确地收敛于预设值，并在保证稳定性的同时提高了收敛速度。实验结果证明了所提方法的有效性和准确性。

在模型预测控制方面，本文针对无界加性高斯扰动提出了一种 SMPC 策略。通过引入逆累积分布函数处理机会约束，并借助概率可达集细化终端约束，保证了算法依概率递归可行与渐近稳定。研究表明，在无界扰动下，该方法能够以一定概率维持系统性能，且较传统 RMPC 与 SMPC 方法具有更低的保守性。

综上所述，本文提出的基于 PWANN 的控制障碍函数逼近方法，以及基于随机模型预测控制与强化学习的机会约束优化算法，从理论与实验层面验证了其在实现系统安全控制与应对不确定性方面的有效性与先进性，为相关领域的研究提供了扎实的理论支撑与实验依据。

纵观全文三个主要章节，本文所提出的方法仍然存在一定的局限性。控制障碍函数的构造主要基于确定性系统模型，而强化学习与随机模型预测控制方法则建立在对扰动分布已知或可估计的假设之上；同时，相关方法在大规模复杂系统中的计算效率与实时性仍有进一步提升空间。就工程应用而言，本文提出的控制策略适用于具有安全约束要求、且扰动统计特性可获得的系统场景，如自动驾驶、机器人系统及能源系统等。未来工作可进一步研究随机系统框架下的控制障碍函数构造方法，并探索其与强化学习或随机模型预测控制的融合机制，以在统一框架下同时刻画安全约束与控制策略优化问题。

参考文献

- [1] CANNON M, KOUVARITAKIS B, WU X. Probabilistic constrained MPC for multiplicative and additive stochastic uncertainty [J]. IEEE Transactions on Automatic Control, 2009, 54 (7): 1626-1632.
- [2] FORSGREN A, GILL P E, WRIGHT M H. Interior methods for nonlinear optimization [J]. SIAM Review, 2002, 44 (4): 525-597.
- [3] MALISANI P, CHAPLAIS F, PETIT N. An interior penalty method for optimal control problems with state and input constraints of nonlinear systems [J]. Optimal Control Applications and Methods, 2016, 37 (1): 3-33.
- [4] TEE K P, GE S S, TAY E H. Barrier lyapunov functions for the control of output-constrained nonlinear systems [J]. Automatica, 2009, 45 (4): 918-927.
- [5] WIELAND P, ALLGÖWER F. Constructive safety using control barrier functions [J]. IFAC Proceedings Volumes, 2007, 40 (12): 462-467.
- [6] SLOTH C, WISNIEWSKI R, PAPPAS G J. On the existence of compositional barrier certificates [C/OL] // 2012 IEEE 51st IEEE Conference on Decision and Control (CDC), Maui, HI, USA, 2012: 4580-4585. <http://dx.doi.org/10.1109/CDC.2012.6426178>.
- [7] WISNIEWSKI R, SLOTH C. Converse barrier certificate theorems [J]. IEEE Transactions on Automatic Control, 2015, 61 (5): 1356-1361.
- [8] PRAJNA S, RANTZER A. Convex programs for temporal verification of nonlinear dynamical systems [J]. SIAM Journal on Control and Optimization, 2007, 46 (3): 999-1021.
- [9] PRAJNA S, JADBABAIE A, PAPPAS G J. A framework for worst-case and stochastic safety verification using barrier certificates [J]. IEEE Transactions on Automatic Control, 2007, 52 (8): 1415-1428.
- [10] BLANCHINI F. Set invariance in control [J]. Automatica, 1999, 35 (11): 1747-1767.
- [11] PRAJNA S, JADBABAIE A. Safety verification of hybrid systems using barrier certificates [C] // Hybrid Systems: Computation and Control, Berlin, Heidelberg, 2004: 477-492.

- [12] PRAJNA S. Barrier certificates for nonlinear model validation [J] . Automatica, 2006, 42 (1) : 117-126.
- [13] PANAGOU D, STIPANOVIĆ D M, VOULGARIS P G. Multi-objective control for multi-agent systems using Lyapunov-like barrier functions [C/OL] //52nd IEEE Conference on Decision and Control, Firenze, Italy, 2013 : 1478-1483. <http://dx.doi.org/10.1109/CDC.2013.6760091>.
- [14] AMES A D, GALLOWAY K, GRIZZLE J W. Control lyapunov functions and hybrid zero dynamics [C/OL] //2012 IEEE 51st IEEE Conference on Decision and Control (CDC), Maui, HI, USA, 2012 : 6837-6842. <http://dx.doi.org/10.1109/CDC.2012.6426229>.
- [15] AMES A D, GALLOWAY K, SREENATH K, et al. Rapidly exponentially stabilizing control lyapunov functions and hybrid zero dynamics [J] . IEEE Transactions on Automatic Control, 2014, 59 (4) : 876-891.
- [16] AMES A D, XU X, GRIZZLE J W, et al. Control barrier function based quadratic programs for safety critical systems [J] . IEEE Transactions on Automatic Control, 2016, 62 (8) : 3861-3876.
- [17] JANKOVIC M. Robust control barrier functions for constrained stabilization of nonlinear systems [J] . Automatica, 2018, 96 : 359-367.
- [18] TAN X, DIMAROGONAS D V. On the undesired equilibria induced by control barrier function based quadratic programs [J] . Automatica, 2024, 159 : 111359.
- [19] SPYRAKOS-PAPASTAVRIDIS E, DAI J S. Minimally model-based trajectory tracking and variable impedance control of flexible-joint robots [J] . IEEE Transactions on Industrial Electronics, 2020, 68 (7) : 6031-6041.
- [20] XU X, WATERS T, PICKEM D, et al. Realizing simultaneous lane keeping and adaptive speed regulation on accessible mobile robot testbeds [C/OL] //2017 IEEE Conference on Control Technology and Applications (CCTA), Maui, HI, USA, 2017 : 1769-1775. <http://dx.doi.org/10.1109/CCTA.2017.8062713>.
- [21] NGUYEN Q, SREENATH K. Safety-critical control for dynamical bipedal walking with precise footstep placement [J] . IFAC-PapersOnLine, 2015, 48 (27) : 147-154.
- [22] EGERSTEDT M, PAULI J N, NOTOMISTA G, et al. Robot ecology: Constraint-based control design for long duration autonomy [J] . Annual Reviews in Control, 2018, 46 : 1-7.

- [23] FERRAGUTI F, BERTULETTI M, LANDI C T, et al. A control barrier function approach for maximizing performance while fulfilling to ISO/TS 15066 regulations [J] . IEEE Robotics and Automation Letters, 2020, 5 (4) : 5921-5928.
- [24] SINGLETARY A, KOLATHAYA S, AMES A D. Safety-critical kinematic control of robotic systems [J] . IEEE Control Systems Letters, 2021, 6 : 139-144.
- [25] PENG C, LIU X, MA J. Design of safe optimal guidance with obstacle avoidance using control barrier function-based actor-critic reinforcement learning [J/OL] . IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2023, 53 (11) : 6861-6873. <http://dx.doi.org/10.1109/TSMC.2023.3288826>.
- [26] WANG K, MENG T, WANG W, et al. Control barrier function based trajectory generation and tracking control for spacecraft inspection mission under multiple safety constraints [J] . Advances in Space Research, 2024, 73 (3) : 2080-2097.
- [27] LEE J, KIM J, AMES A D. A data-driven method for safety-critical control: Designing control barrier functions from state constraints [J/OL] . 2024 American Control Conference (ACC), 2023 : 394-401. <https://api.semanticscholar.org/CorpusID:266191120>.
- [28] DU D, HAN S, QI N, et al. Reinforcement learning for safe robot control using control lyapunov barrier functions [C/OL] //2023 IEEE International Conference on Robotics and Automation (ICRA), London, United Kingdom, 2023 : 9442-9448. <http://dx.doi.org/10.1109/ICRA48891.2023.10160991>.
- [29] SCUKINS E, ÖGREN P. Using reinforcement learning to create control barrier functions for explicit risk mitigation in adversarial environments [C/OL] //2021 IEEE International Conference on Robotics and Automation (ICRA), Xi'an, China, 2021 : 10734-10740. <http://dx.doi.org/10.1109/ICRA48506.2021.9561853>.
- [30] SAVERIANO M, LEE D. learning barrier functions for constrained motion planning with dynamical systems [J/OL] . 2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2019 : 112-119. <https://api.semanticscholar.org/CorpusID:210971212>.
- [31] SRINIVASAN M, DABHOLKAR A, COOGAN S, et al. Synthesis of control barrier functions using a supervised machine learning approach [J/OL] . 2020 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2020 : 7139-7145. <https://api.semanticscholar.org/CorpusID:212657768>.

- [32] TAYLOR A, SINGLETARY A, YUE Y, et al. Learning for safety-critical control with control barrier functions [C] //Proceedings of the 2nd Conference on Learning for Dynamics and Control : Vol 120, Virtual Conference, 2020 : 708-717.
- [33] YAGHOUBI S, FAINEKOS G, SANKARANARAYANAN S. Training neural network controllers using control barrier functions in the presence of disturbances [J] . 2020 IEEE 23rd International Conference on Intelligent Transportation Systems (ITSC), 2020 : 1-6.
- [34] LINDEMANN L, HU H, ROBEY A, et al. Learning hybrid control barrier functions from data [C] //Proceedings of Machine Learning Research, Vol 155 : Proceedings of the 2020 Conference on Robot Learning, Virtual Conference, 2021 : 1351-1370.
- [35] YANG Y, CHEN L, GOMBOLAY M. Safe inverse reinforcement learning via control barrier function [J/OL] . arXiv preprint arXiv:2212.02753, 2022. <https://arxiv.org/abs/2212.02753>.
- [36] ROBEY A, HU H, LINDEMANN L, et al. Learning control barrier functions from expert demonstrations [C] //2020 59th IEEE Conference on Decision and Control (CDC), [S.l.], 2020 : 3717-3724.
- [37] SO O, SERLIN Z, MANN M, et al. How to train your neural control barrier function: learning safety filters for complex input-constrained systems [C/OL] //2024 IEEE International Conference on Robotics and Automation (ICRA), Yokohama, Japan, 2024 : 11532-11539. <http://dx.doi.org/10.1109/ICRA57147.2024.10610418>.
- [38] LINDEMANN L, ROBEY A, JIANG L, et al. Learning robust output control barrier functions from safe expert demonstrations [J] . IEEE Open Journal of Control Systems, 2024, 3 : 158-172.
- [39] NGUYEN T T, NGUYEN N D, NAHAVANDI S. Deep reinforcement learning for multiagent systems: A review of challenges, solutions, and applications [J] . IEEE Transactions on Cybernetics, 2020, 50 (9) : 3826-3839.
- [40] MOUSAVI S S, SCHUKAT M, HOWLEY E. Deep reinforcement learning: An overview [C] //Proceedings of SAI Intelligent Systems Conference (IntelliSys) 2016: Volume 2, London, UK, 2018 : 426-440.
- [41] HINTON G E, OSINDERO S, TEH Y-W. A fast learning algorithm for deep belief nets [J] . Neural Computation, 2006, 18 (7) : 1527-1554.

- [42] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning [J]. Nature, 2015, 518 (7540): 529-533.
- [43] VINYALS O, BABUSCHKIN I, CZARNECKI W M, et al. Grandmaster level in Starcraft II using multi-agent reinforcement learning [J]. Nature, 2019, 575 (7782): 350-354.
- [44] KIRAN B R, SOBH I, TALPAERT V, et al. Deep reinforcement learning for autonomous driving: A survey [J]. IEEE Transactions on Intelligent Transportation Systems, 2021, 23 (6): 4909-4926.
- [45] KOBER J, BAGNELL J A, PETERS J. Reinforcement learning in robotics: A survey [J]. The International Journal of Robotics Research, 2013, 32 (11): 1238-1274.
- [46] AFSAR M M, CRUMP T, FAR B. Reinforcement learning based recommender systems: A survey [J]. ACM Computing Surveys, 2022, 55 (7): 1-38.
- [47] UC-CETINA V, NAVARRO-GUERRERO N, MARTIN-GONZALEZ A, et al. Survey on reinforcement learning for language processing [J]. Artificial Intelligence Review, 2023, 56 (2): 1543-1575.
- [48] WATKINS C J, DAYAN P. Q-Learning [J]. Machine Learning, 1992, 8: 279-292.
- [49] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Playing atari with deep reinforcement learning [J/OL]. arXiv preprint arXiv:1312.5602, 2013. <https://arxiv.org/abs/1312.5602>.
- [50] SCHULMAN J, LEVINE S, ABBEEL P, et al. Trust region policy optimization [C]. // Proceedings of the 32nd International Conference on Machine Learning: Vol 37, Lille, France, 2015: 1889-1897.
- [51] SCHULMAN J, WOLSKI F, DHARIWAL P, et al. Proximal policy optimization algorithms [J/OL]. arXiv preprint arXiv:1707.06347, 2017. <https://arxiv.org/abs/1707.06347>.
- [52] FEINBERG V, WAN A, STOICA I, et al. Model-based value estimation for efficient model-free reinforcement learning [J/OL]. arXiv preprint arXiv:1803.00101, 2018. <https://arxiv.org/abs/1803.00101>.
- [53] WEBER T, RACANIÈRE S, REICHERT D P, et al. Imagination-augmented agents for deep reinforcement learning [J/OL]. arXiv preprint arXiv:1707.06203, 2017. <https://arxiv.org/abs/1707.06203>.

- [54] HA D, SCHMIDHUBER J. World models [J/OL] . arXiv preprint arXiv:1803.10122, 2018. <https://arxiv.org/abs/1803.10122>.
- [55] CLARKE D W, MOHTADI C, TUFFS P S. Generalized predictive control—part I. The basic algorithm [J] . Automatica, 1987, 23 (2) : 137-148.
- [56] RAWLINGS J B, MUSKE K R. The stability of constrained receding horizon control [J] . IEEE Transactions on Automatic Control, 1993, 38 (10) : 1512-1516.
- [57] MAYNE D, MICHALSKA H. Receding horizon control of nonlinear systems [J/OL] . IEEE Transactions on Automatic Control, 1990, 35 (7) : 814-824. <http://dx.doi.org/10.1109/9.57020>.
- [58] MICHALSKA H, MAYNE D Q. Receding horizon control of nonlinear systems without differentiability of the optimal value function [J] . Systems & Control Letters, 1991, 16 (2) : 123-130.
- [59] CHEN H, ALLGÖWER F. A Quasi-infinite horizon nonlinear model predictive control scheme with guaranteed stability [J] . Automatica, 1998, 34 (10) : 1205-1217.
- [60] 孙中奇. 轮式机器人跟踪控制研究: 模型预测控制方法 [D] . 北京: 北京理工大学, 2018.
- [61] CANNON M, KOUVARITAKIS B, RAKOVIĆ S V, et al. Stochastic tubes in model predictive control with probabilistic constraints [J] . IEEE Transactions on Automatic Control, 2010, 56 (1) : 194-200.
- [62] KOUVARITAKIS B, CANNON M, RAKOVIĆ S V, et al. Explicit use of probabilistic distributions in linear predictive control [J] . Automatica, 2010, 46 (10) : 1719-1724.
- [63] LANGSON W, CHRYSOCHOOS I, RAKOVIĆ S, et al. Robust model predictive control using tubes [J] . Automatica, 2004, 40 (1) : 125-133.
- [64] PARISIO A, MOLINARI M, VARAGNOLO D, et al. A scenario-based predictive control approach to building HVAC management systems [C/OL] // 2013 IEEE International Conference on Automation Science and Engineering (CASE), Madison, WI, USA, 2013 : 428-435. <http://dx.doi.org/10.1109/CoASE.2013.6654024>.
- [65] SHANG C, YOU F. A data-driven robust optimization approach to scenario-based stochastic model predictive control [J] . Journal of Process Control, 2019, 75 : 24-39.

- [66] BERNARDINI D, BEMPORAD A. Scenario-based model predictive control of stochastic constrained linear systems [C/OL] //Proceedings of the 48h IEEE Conference on Decision and Control (CDC) held jointly with 2009 28th Chinese Control Conference, Shanghai, China, 2009 : 6333-6338. <http://dx.doi.org/10.1109/CDC.2009.5399917>.
- [67] OLDEWURTEL F, JONES C N, MORARI M. A tractable approximation of chance constrained stochastic MPC based on affine disturbance feedback [C/OL] //2008 47th IEEE Conference on Decision and Control, Cancun, Mexico, 2008 : 4731-4736. <http://dx.doi.org/10.1109/CDC.2008.4738806>.
- [68] PAULSON J A, STREIF S, MESBAH A. Stability for receding-horizon stochastic model predictive control [C/OL] //2015 American Control Conference (ACC), Chicago, IL, USA, 2015 : 937-943. <http://dx.doi.org/10.1109/ACC.2015.7170854>.
- [69] HOKAYEM P, CINQUEMANI E, CHATTERJEE D, et al. Stochastic receding horizon control with output feedback and bounded controls [J] . Automatica, 2012, 48 (1) : 77-88.
- [70] KÖGEL M, FINDEISEN R. Reducing conservatism in stochastic model predictive blending multiple control gains [C/OL] //2021 American Control Conference (ACC), New Orleans, LA, USA, 2021 : 2094-2101. <http://dx.doi.org/10.23919/ACC50511.2021.9483134>.
- [71] LORENZEN M, DABBENE F, TEMPO R, et al. Constraint-tightening and stability in stochastic model predictive control [J] . IEEE Transactions on Automatic Control, 2016, 62 (7) : 3165-3177.
- [72] ARCARI E, IANNELLI A, CARRON A, et al. Stochastic MPC with robustness to bounded parametric uncertainty [J] . IEEE Transactions on Automatic Control, 2023, 68 (12) : 7601-7615.
- [73] KORDA M, GONDHALEKAR R, CIGLER J, et al. Strongly feasible stochastic model predictive control [C/OL] //2011 50th IEEE Conference on Decision and Control and European Control Conference, Orlando, FL, USA, 2011 : 1245-1251. <http://dx.doi.org/10.1109/CDC.2011.6161250>.
- [74] HEWING L, WABERSICH K P, ZEILINGER M N. Recursively feasible stochastic model predictive control using indirect feedback [J] . Automatica, 2020, 119 : 109095.

- [75] GUERRIER M, FOUAD H, BELTRAME G. Learning control barrier functions and their application in reinforcement learning: A survey [J/OL] . arXiv preprint arXiv:2404.16879, 2024. <https://arxiv.org/abs/2404.16879>.
- [76] AMES A D, COOGAN S, EGERSTEDT M, et al. Control barrier functions: Theory and applications [C/OL] // 2019 18th European Control Conference (ECC), Naples, Italy, 2019 : 3420-3431. <http://dx.doi.org/10.23919/ECC.2019.8796030>.
- [77] BORRELLI F, BEMPORAD A, MORARI M. Predictive control for linear and hybrid systems [M] . [S.l.] : Cambridge University Press, 2017.
- [78] KVASNICA M, GRIEDER P, BAOTIĆ M, et al. Multi-parametric toolbox (MPT) [C] // Hybrid Systems: Computation and Control, Berlin, Heidelberg, 2004 : 448-462.
- [79] DANIELSON C, BORRELLI F. Symmetric explicit model predictive control [J] . IFAC Proceedings Volumes, 2012, 45 (17) : 132-137.
- [80] KARG B, LUCIA S. Efficient representation and approximation of model predictive control laws via deep learning [J] . IEEE Transactions on Cybernetics, 2020, 50 (9) : 3866-3878.
- [81] ANEVLAVIS T, LIU Z, OZAY N, et al. Controlled invariant sets: Implicit closed-form representations and applications [J] . IEEE Transactions on Automatic Control, 2023, 69 (7) : 4506-4521.
- [82] KÜÇÜKYAVUZ S, JIANG R. Chance-constrained optimization under limited distributional information: a review of reformulations based on sampling and distributional robustness [J] . EURO Journal on Computational Optimization, 2022, 10 : 100030.
- [83] TARIM S A, MANANDHAR S, WALSH T. Stochastic constraint programming: A scenario-based approach [J] . Constraints, 2006, 11 : 53-80.
- [84] ZHOU X, WANG X, HUANG T, et al. Hybrid intelligence assisted sample average approximation method for chance constrained dynamic optimization [J] . IEEE Transactions on Industrial Informatics, 2020, 17 (9) : 6409-6418.
- [85] GELETU A, HOFFMANN A, KLOPPEL M, et al. An inner-outer approximation approach to chance constrained optimization [J] . SIAM Journal on Optimization, 2017, 27 (3) : 1834-1857.

- [86] LI Z, LI Z. Optimal robust optimization approximation for chance constrained optimization problem [J] . Computers & Chemical Engineering, 2015, 74 : 89-99.
- [87] GUAN Y, REN Y, LI S E, et al. Centralized cooperation for connected and automated vehicles at intersections by proximal policy optimization [J] . IEEE Transactions on Vehicular Technology, 2020, 69 (11) : 12597-12608.
- [88] PENG B, MU Y, GUAN Y, et al. Model-based actor-critic with chance constraint for stochastic system [C/OL] // 2021 60th IEEE Conference on Decision and Control (CDC), Austin, TX, USA, 2021 : 4694-4700. <http://dx.doi.org/10.1109/CDC45484.2021.9683748>.
- [89] CHOW Y, GHAVAMZADEH M, JANSON L, et al. Risk-constrained reinforcement learning with percentile risk criteria [J] . Journal of Machine Learning Research, 2018, 18 (167) : 1-51.
- [90] PATERNAIN S, CALVO-FULLANA M, CHAMON L F O, et al. Learning safe policies via primal-dual methods [C/OL] // 2019 IEEE 58th Conference on Decision and Control (CDC), Nice, France, 2019 : 6491-6497. <http://dx.doi.org/10.1109/CDC40024.2019.9029423>.
- [91] PENG B, MU Y, DUAN J, et al. Separated proportional-integral lagrangian for chance constrained reinforcement learning [C/OL] // 2021 IEEE Intelligent Vehicles Symposium (IV), Nagoya, Japan, 2021 : 193-199. <http://dx.doi.org/10.1109/IV48863.2021.9575205>.
- [92] SCHWENZER M, AY M, BERGS T, et al. Review on model predictive control: An engineering perspective [J] . The International Journal of Advanced Manufacturing Technology, 2021, 117 (5) : 1327-1349.
- [93] MAYNE D Q, RAWLINGS J B, RAO C V, et al. Constrained model predictive control: Stability and optimality [J] . Automatica, 2000, 36 (6) : 789-814.
- [94] CANNON M, KOUVARITAKIS B, NG D. Probabilistic tubes in linear stochastic model predictive control [J] . Systems & Control Letters, 2009, 58 (10-11) : 747-753.
- [95] GILBERT E G, TAN K T. Linear systems with state and control constraints: The theory and application of maximal output admissible sets [J] . IEEE Transactions on Automatic control, 1991, 36 (9) : 1008-1020.

- [96] FANG X, CHEN W-H. Model predictive control with preview: Recursive feasibility and stability [J]. IEEE Control Systems Letters, 2022, 6 : 2647-2652.
- [97] HEWING L, CARRON A, WABERSICH K P, et al. On a correspondence between probabilistic and robust invariant sets for linear systems [C/OL] //2018 European Control Conference (ECC), Limassol, Cyprus, 2018 : 1642-1647. <http://dx.doi.org/10.23919/ECC.2018.8550160>.
- [98] BORRELLI F, BEMPORAD A, MORARI M. Predictive control for linear and hybrid systems [M]. Cambridge, UK : Cambridge University Press, 2017.
- [99] LIMÓN D, ALVARADO I, ALAMO T, et al. Robust tube-based MPC for tracking of constrained linear systems with additive disturbances [J]. Journal of Process Control, 2010, 20 (3) : 248-260.

附录 A

A.1 第二章九维系统实验相关图




图 A-1 9D 安全采样数据集 X_{safe} 投影 1 ~ 6




图 A-2 9D 安全采样数据集 X_{safe} 投影 7 ~ 12




图 A-3 9D 安全采样数据集 X_{safe} 投影 13 ~ 18




图 A-4 9D 安全采样数据集 X_{safe} 投影 19 ~ 24




图 A-5 9D 安全采样数据集 X_{safe} 投影 25 ~ 30







图 A-6 9D 安全采样数据集 X_{safe} 投影 31 ~ 36




(a) 9D 总 Loss




(b) 9D $Loss_{safe}$



(c) 9D $Loss_{unsafe}$



(d) 9D $Loss_{CBF}$



(e) 9DCBF 条件满足比例

图 A-7 9D 系统训练结果




图 A-8 9D 系统训练结果投影 1 ~ 6




图 A-9 9D 系统训练结果投影 7 ~ 12




图 A-10 9D 系统训练结果投影 13 ~ 18




图 A-11 9D 系统训练结果投影 19 ~ 24




图 A-12 9D 系统训练结果投影 25 ~ 30




图 A-13 9D 系统训练结果投影 31 ~ 36

攻读硕士学位期间取得创新性成果

（一）发表的学术论文

- [1] J. Zhao and J. Xu, "Probabilistically Recursively Feasible Stochastic MPC with Low Conservatism under Unbounded Disturbance," 2025 40th Youth Academic Annual Conference of Chinese Association of Automation (YAC), Zhengzhou, China, 2025, pp. 1857-1862, doi: 10.1109/YAC66630.2025.11149855.

致 谢

时光荏苒，硕士研究生阶段的求学时光即将画上句点。站在这个人生的重要节点回望，数载光阴如一幅徐徐展开的画卷，记录着我在学术道路上的探索与成长，也镌刻着无数温暖的陪伴与支持。这段旅程中，我收获的不仅是专业知识的积累与科研能力的提升，更是独立思考能力的培养和意志品质的锤炼。在此，谨向所有曾给予我指导、帮助与支持的师长、同窗和亲人，表达内心最诚挚的感恩。

衷心感谢我的导师许鋈教授在我整个科研生涯中给予的悉心指导。在课题立项初期，许老师以其敏锐的学术眼光，帮助我确定了既有研究价值又契合我个人能力的研究方向。在实验遇到瓶颈时，她总能及时指出问题的关键所在，引导我找到解决方案。特别是在模型优化阶段，许老师提出的多项建议让研究取得了突破性进展。在论文写作过程中，许老师对每一稿都进行了认真批阅，从整体结构到论证逻辑，都给予了细致指导。她严谨的治学态度和深厚的学术素养，不仅保证了论文质量，更让我学到了宝贵的科研方法。除了学术上的指导，许老师严谨务实的科研态度和处事原则也深深影响了我。她对待科研工作的专业精神，让我明白了学术研究需要持之以恒的投入和精益求精的态度。在与她共事的过程中，我逐渐学会了如何在面对困难时保持冷静，如何在追求创新时不忘根本。这些宝贵的品质不仅帮助我完成了学业，更将成为我未来职业生涯中的重要财富。许老师的言传身教，让我深刻理解到治学与做人的内在统一，这份领悟远比知识本身更加珍贵。在此，谨向许老师表达最诚挚的谢意。您的教诲将永远铭记于心，成为我未来科研道路上最宝贵的精神财富。

同时，我要衷心感谢课题组的每一位伙伴。感谢贾皓文、李昕、徐政琪三位同窗的陪伴与支持，在那些共同奋战的日夜里，我们互相鼓励，携手前行。特别感谢李鸿懿师兄在实验设计和数据分析方面给予的宝贵建议，让我少走了不少弯路。也要感谢各位师弟师妹在实验过程中的协助。这段并肩作战的岁月，因有你们的陪伴而显得格外珍贵，这份同门之谊我将永远珍藏。

此外，感谢学院和学校为我们营造的优良学术环境和提供的全方位支持。学院图书馆拥有丰富的专业藏书和电子资源，涵盖了国内外重要的学术期刊和数据库，这为我的文献调研和理论研究工作提供了坚实的基础。每当我需要查阅相关资料时，总能及时获取最新的学术信息，这对我的研究进展起到了关键

作用。在课程学习阶段，各位授课老师的悉心教导让我受益匪浅。他们不仅系统地传授了专业知识，更注重培养我们的学术素养和研究能力。通过参与课堂讨论和专题研讨，我逐步掌握了独立开展研究的方法。老师们严谨的治学态度和启发式的教学方法，让我在掌握专业知识的同时，也学会了如何发现和解决学术问题。学院定期举办的学术讲座和学术沙龙，为我提供了宝贵的学术交流平台。在这些活动中，我不仅了解到学科前沿动态，还有机会与来自不同领域的学者交流思想，这些经历极大地拓宽了我的学术视野。特别要感谢学院教务老师和图书馆工作人员，他们在日常学习和研究中给予了我们很多帮助和支持。这些完善的学术资源和支持体系，为我的理论研究工作创造了良好条件，使我能够专注于学术探索，最终顺利完成学业。

最后，最深切的感恩要献给我最亲爱的家人。感谢父母一直以来的理解与支持，你们无私的爱是我最坚强的后盾。在我面临压力与挑战时，是你们的鼓励给了我继续前行的勇气；在我取得进步时，是你们分享我的喜悦。你们的信任与陪伴，始终是我人生道路上最温暖的明灯。

站在我求学生涯的终点回望，这段旅程因无数温暖的陪伴而显得弥足珍贵。感谢所有在这段路上给予我光亮的人。这段时光馈赠予我的，不仅是知识的积淀，更是生命的成长。在实验室里度过的深夜，在图书馆里翻阅的书页，在讨论中迸发的灵感，都已成为我生命中不可磨灭的印记。它们让我学会在迷茫中保持清醒，在挫折中坚守初心，在平凡中追求卓越。带着这些收获，我将踏上新的征程。未来或许会有风雨，但这段岁月赋予我的勇气与智慧，将始终照亮前行的路。愿我们都能在各自的人生舞台上，活出最好的模样。

此去经年，愿不负韶华；山高水长，愿初心不忘。